

UNIVERSIDADE FEDERAL DE MINAS GERAIS

ICEx - Instituto de Ciências Exatas

Mateus Aguilar Batista

Dinâmicas Temporais no Futebol: Uma abordagem estatística para modelagem e previsão

BELO HORIZONTE

2025

Mateus Aguilar Batista

Dinâmicas Temporais no Futebol: Uma abordagem estatística para modelagem e previsão

Trabalho de Conclusão de Curso apresentado à comissão de Graduação do Departamento de Estatística da Universidade Federal de Minas Gerais, como parte dos requisitos para a obtenção do título de Bacharel em Estatística.

Orientador: Uriel Moreira Silva

Belo Horizonte
2025

Declaro ter ciência do envio desse Relatório Final na data de hoje, 18/07/2025, pelo aluno Mateus Aguilar Batista.

gov.br
Documento assinado digitalmente
URIEL MOREIRA SILVA
Data: 18/07/2025 00:07:07-0300
Verifique em https://validar.iti.gov.br

Agradecimentos

Agradeço, primeiramente, a Deus, por me conceder saúde, sabedoria e forças para seguir em frente durante toda essa caminhada.

Ao meu orientador, Prof. Uriel Moreira Silva, minha sincera gratidão pela orientação dedicada, paciência e apoio fundamental ao longo deste trabalho.

Aos meus pais, Afrânio e Isabel, por todo amor, ensinamentos e pelo exemplo de integridade e perseverança. À minha irmã Natércia, meu suporte constante, obrigada por estar ao meu lado nos momentos mais desafiadores.

Agradeço também aos meus colegas, amigos e a todos que, de alguma forma, fizeram parte dessa jornada, contribuindo com palavras de incentivo, apoio emocional ou mesmo com gestos simples que fizeram grande diferença.

"Os dados contam uma história."

— Brené Brown

Resumo

A análise de resultados no futebol tem ganhado destaque no âmbito esportivo, econômico e social. Considerado o esporte mais popular do mundo, o futebol movimenta bilhões de torcedores, além de impactar globalmente em uma indústria multibilionária em conjunto. Nos últimos anos, o "boom" das apostas esportivas teve um impacto significativo na intenção de encontrar formas estatísticas mais precisas, capazes de prever resultados de confrontos. Nesse cenário, a análise de desempenho e o uso de informações históricas passaram a fazer parte de um parte de um complemento estratégico para tomada de decisão em diversas áreas do esporte. Paralelamente, a internacionalização do futebol foi intensificada com a ida de grandes nomes como Lionel Messi e Cristiano Ronaldo para ligas menos expressivas, contribuiu para o fortalecimento do esporte em regiões com menor representatividade no cenário global.

A escolha do tema se justifica pelo momento atual vivido pelo futebol, que atravessa uma fase de enorme visibilidade impulsionada pelo crescimento do mercado de apostas esportivas. No Brasil, esse movimento ganhou ainda mais força com a regulamentação oficial das "bets" em 2023, o que abriu espaço para a profissionalização do setor e para o desenvolvimento de análises mais robustas baseadas em dados. Dessa forma, o uso de modelos estatísticos surge como uma ferramenta promissora, tanto para fins acadêmicos quanto comerciais, ajudando a transformar o futebol em um verdadeiro campo de estratégias orientadas por dados.

O presente trabalho busca classificar resultados de partidas de futebol através dos gols marcados, considerando tanto o número de gols em si, como o resultado final, que pode ser vitória, empate ou derrota. Para isso, serão usados modelos estáticos e dinâmicos, que analisam o comportamento dos times com base em suas informações históricas.

Palavras-chave: Futebol; Modelos Linares Generalizados; Modelos Mistos, Modelos Dinâmicos.

Sumário

Sumário **7**
1 Introdução **8**
2 Metodologia **10**
2.1 **Conjunto de dados: Campeonato Brasileiro dos anos 2003-2024** . 10
2.2 **Modelos Estáticos para número de gols** 11
2.2.1 Modelo Poisson 11
2.2.2 Modelo Binomial Negativo 12
2.2.3 Modelo Normal 13
2.3 **Modelos Dinâmicos para número de gols** 14
2.4 Modelos Dinâmicos para Previsão de Gols 14
2.4.1 Modelo Poisson Dinâmico 15
2.4.2 Modelo Normal Dinâmico 16
2.4.3 Observações 16
2.5 Modelos Estáticos para previsão de Resultados 17
2.5.1 Modelo Logístico Multinomial 17
2.6 Critérios de Classificação dos Modelos 17
2.7 Análise de Resíduos 18
3 Resultados **20**
3.1 Modelos Estáticos 21
3.1.1 Modelo Normal 21
3.1.2 Modelo Poisson 22
3.1.3 Modelo Binomial Negativo 22
3.2 Modelo Logístico Multinomial 23
3.3 Modelos Dinâmicos 24
3.3.1 Modelo Normal 24
3.3.2 Modelo Poisson 25
3.4 Análise de Resíduos 26
3.4.1 Modelos Estáticos 26
3.4.2 Modelos Dinâmicos 28
4 Conclusão **29**
Bibliografia **30**
ANEXO A Código-Fonte R **31**

1 Introdução

O futebol não se restringe apenas às quatro linhas. Mais que um esporte, é um dos fenômenos sociais e culturais mais expressivos da contemporaneidade, como destaca Silva (2001) [8]. Seu alcance transcende barreiras e sua capacidade de mobilizar paixões e interesses financeiros o tornaram objeto importante de estudo em diversas áreas do conhecimento. Muito mais do que um jogo, o futebol tornou-se parte fundamental das estruturas midiáticas e de entretenimento de diversos países, além de movimentar uma indústria multibilionária que abrange clubes, marcas, direitos de transmissão, plataformas digitais e, mais recentemente, o crescente mercado das apostas esportivas.

Nos últimos anos, a regulamentação desse setor [2] — como ocorreu no Brasil com a sanção da Lei nº 14.790, de 29 de dezembro de 2023, que estabeleceu o marco legal para a exploração comercial das apostas de quota fixa, popularmente conhecidas como "*bets*" — impulsionou uma nova frente de interesse: a tentativa de prever, de maneira cada vez mais precisa, os resultados das partidas. A legalização das apostas esportivas não apenas profissionalizou o setor, mas também ampliou a demanda por modelos estatísticos robustos capazes de embasar decisões e reduzir incertezas.

A possibilidade de antecipar desfechos como vitórias, empates ou derrotas, assim como o número de gols marcados em cada jogo, representa um desafio para a construção de modelos preditivos confiáveis. Em ligas como o Campeonato Brasileiro, conhecidas pelo seu alto grau de equilíbrio competitivo, prever resultados se torna ainda mais complexo. Diferentemente de ligas europeias (dominadas por grandes clubes), o cenário brasileiro é caracterizado por uma rotatividade constante nas primeiras posições da tabela, mudanças frequentes de treinadores, elencos relativamente nivelados e um calendário sobrecarregado, o que amplia a margem de imprevisibilidade — um aspecto amplamente reconhecido por Groll (2018) [3], que explora justamente como esse nível de incerteza desafia a eficácia de modelos estatísticos em torneios de alto rendimento.

O avanço das técnicas de análise de dados e *machine learning* tem aberto novas perspectivas para o estudo quantitativo do futebol. Modelos como os Modelos Lineares Generalizados (GLM) têm sido amplamente utilizados para prever padrões nos jogos a partir de variáveis históricas. Estudos como os de Padilha (2022) [7] mostram como a incorporação de variáveis contextuais – desempenho em casa e fora, sequência de resultados recentes, eficiência ofensiva e defensiva – pode melhorar significativamente a acurácia das

previsões.

Neste contexto, o presente trabalho tem como objetivo desenvolver e avaliar modelos estatísticos para a previsão de resultados no Campeonato Brasileiro, com foco especial na modelagem da distribuição de gols como base para a classificação dos desfechos das partidas. A pesquisa se justifica tanto por seu potencial de contribuição acadêmica – avançando no estudo de modelos preditivos em ambientes de alta variância – quanto por suas aplicações práticas, que incluem desde o mercado de apostas esportivas até a análise de desempenho e tomada de decisão estratégica por parte dos clubes.

2 Metodologia

Neste capítulo, será apresentada a metodologia utilizada para o desenvolvimento do trabalho. São descritos os dados empregados, os critérios de seleção e tratamento das informações, bem como os modelos estatísticos aplicados na previsão dos resultados das partidas do Campeonato Brasileiro de Futebol – Série A. A análise envolveu tanto a modelagem da quantidade de gols quanto a classificação dos desfechos das partidas (vitória, empate ou derrota), com o objetivo de investigar o desempenho preditivo de diferentes abordagens estatísticas. Todas as etapas, desde o pré-processamento dos dados até a avaliação da acurácia dos modelos, serão detalhadas nas seções seguintes.

2.1 Conjunto de dados: Campeonato Brasileiro dos anos 2003-2024

Para o desenvolvimento deste trabalho, foram coletados dados dos anos de 2003 até 2024 da série A do Campeonato Brasileiro de Futebol. Os dados foram retirados a partir de um repositório do Github (salvnetto/FootStats-Data). Para a estimação/treino dos modelos, foram analisados 380 jogos do ano de 2024 (até a trigésima rodada do campeonato), enquanto que para realizar as previsões, analisaram-se os resultados das rodadas de nº 31 até a de nº 34.

As principais variáveis no conjunto de dados utilizado neste trabalho são descritas a seguir:

- **season:** ano correspondente à temporada do Campeonato Brasileiro em que a partida foi realizada
- **round:** rodada em que a partida ocorreu
- **date:** Data em que a partida foi disputada, no formato "YYYY-MM-DD"
- **venue:** Indicador do local da partida. Assume os valores (**"Home"**) (quando a equipe atuou como mandante) ou (**"Away"**) (quando atuou como visitante).
- **result:** Resultado final da partida. Assume os valores "W"(vitória), "D"(empate) ou "L"(derrota).

- **team_name:** nome da equipe principal na partida
- **opponent:** nome da equipe adversária na partida
- **gf:** número de gols marcados pela equipe principal na partida
- **ga:** número de gols sofridos pela equipe principal na partida

2.2 Modelos Estáticos para número de gols

Os modelos considerados nesse trabalho são da classe dos Modelos lineares Generalizados Mistos (GLMM, do inglês *Generalized Linear Mixed Models*). A estrutura naturalmente hierárquica desses modelos permite a inclusão de efeitos aleatórios capturando as especificidades de cada time (*team_name*) quando modelamos os seus próprios gols, assim como os efeitos específicos à cada um dos adversários correspondentes (*opponent*).

Mais especificamente, seja Y_{ijt} o número de gols feito pelo time i no adversário j durante a rodada t. Todos os modelos estáticos que vamos considerar aqui satisfazem então uma estrutura condicional média com a seguinte forma geral:

$$g\big(\mathbb{E}[Y_{ijt}|\boldsymbol{X}_{ijt}]\big) = \alpha + u_i^{(atk)} - u_j^{(def)}, \tag{2.1}$$

em que $g(\cdot)$ é uma função de ligação, α é um intercepto, $u_i^{(atk)} \sim \mathcal{N}(0, \sigma^2_{atk})$ é o efeito ataque do time i e $u_j^{(def)} \sim \mathcal{N}(0, \sigma^2_{def})$ é o efeito defesa do time j, de modo que quando o time i joga contra o time j, seu efeito ataque aumenta seu número de gols, enquanto o efeito defesa do adversário reduz o seu número de gols. $\boldsymbol{X}_{ijt}$ aqui representa toda a informação condicional sobre a partida correspondente, e supomos que $u_i^{(atk)}$ e $u_j^{(def)}$ são independentes para todo i e j.

Naturalmente, a relação ataque-defesa também vale para quando time j joga contra o time i, e para o mesmo jogo no banco de dados são obtidos na verdade informações sobre "2 resultados" – o do time i contra o time j (sob a ótica do time i e relativo à quantos gols esse time fez, isto é, Y_{ijt}) e o do time j contra o time i (sob a ótica do time j e relativo à quantos gols esse time fez, isto é, Y_{jit}). Note que, como temos 20 times e 40 rodadas na Série A do Campeonato Brasileiro, então $i, j = 1, \ldots, 20$ e $t = 1, \ldots, 40$.

Finalmente, outros fatores relevantes para o número de gols de um time (como o efeito do mando de campo, isto é, quando o time joga "em casa") podem ser inclusos na forma dada em (2.1) através de efeitos fixos e/ou aleatórios, podendo inclusive ser específicos à cada time.

2.2.1 Modelo Poisson

O modelo de Poisson é um modelo clássico da Estatística para lidar com variáveis de contagem, como o número de gols em partidas de futebol [6]. Ele assume que os eventos

(gols) ocorrem de forma independente, com uma taxa média constante, e que a variância da distribuição é igual à sua média. A função de ligação logarítmica garante que a média dos gols previstos permaneça positiva, o que é essencial em modelos de contagem.

A formulação matemática do modelo é:

$$Y_{ijt}|\boldsymbol{X}_{ijt} \sim \text{Poisson}(\lambda_{ijt}) \tag{2.2}$$

$$\log(\lambda_{ijt}) = \alpha + u_i^{(\text{atk})} - u_j^{(\text{def})} + \beta_{\text{home}} \cdot \text{home}_{ijt}, \tag{2.3}$$

onde:

- Y_{ijt}: número de gols marcados pelo time i contra o time j na rodada t;
- $\boldsymbol{X}_{ijt}$: informação condicional sobre a partida do time i contra o time j na rodada t;
- λ_{ijt}: taxa média de gols esperada;
- α é o intercepto global;
- β_{home}: efeito fixo associado ao mando de campo;
- home_{ijt}: variável indicadora (1 se o time i for mandante contra o time j na rodada t, 0 caso contrário);
- $u_i^{(atk)} \sim \mathcal{N}(0, \sigma_{atk}^2)$: efeito aleatório de ataque do time i;
- $u_j^{(def)} \sim \mathcal{N}(0, \sigma_{def}^2)$: efeito aleatório de defesa do time j.

2.2.2 Modelo Binomial Negativo

A distribuição Binomial Negativa estende o modelo de Poisson ao permitir que a variância dos dados exceda a média, situação comum em jogos de futebol com alta variabilidade no número de gols. Essa flexibilidade adicional torna o modelo mais realista para campeonatos competitivos, como o Brasileirão. Ao introduzir um parâmetro de dispersão adicional (θ), o modelo Binomial Negativo lida melhor com a *sobredispersão*, ou seja, quando a variabilidade observada nos dados é maior do que aquela predita por um modelo Poisson tradicional [4].

Sua formulação é dada por:

$$Y_{ijt}|\boldsymbol{X}_{ijt} \sim \text{NegBin}(\mu_{ijt}, \theta) \tag{2.4}$$

$$\log(\mu_{ijt}) = \alpha + u_i^{(\text{atk})} - u_j^{(\text{def})} + \beta_{\text{home}} \cdot \text{home}_{ijt}, \tag{2.5}$$

onde:

- Y_{ijt}: número de gols marcados pelo time i contra o time j na rodada t;

- $\boldsymbol{X}_{ijt}$: informação condicional sobre a partida do time i contra o time j na rodada t;
- μ_{ijt}: média esperada do número de gols;
- θ: parâmetro de dispersão da distribuição;
- α é o intercepto global;
- β_{home}: efeito fixo associado ao mando de campo;
- home_{ijt}: variável indicadora (1 se o time i for mandante contra o time j na rodada t, 0 caso contrário);
- $u_i^{(atk)} \sim \mathcal{N}(0, \sigma_{atk}^2)$: efeito aleatório de ataque do time i;
- $u_j^{(def)} \sim \mathcal{N}(0, \sigma_{def}^2)$: efeito aleatório de defesa do time j.

2.2.3 Modelo Normal

Embora o número de gols seja uma variável discreta, a modelagem pela distribuição Normal pode ser usada como uma aproximação quando o foco da análise seja na média dos gols marcados, e não nas contagens exatas.

A suposição de normalidade pode ser razoável quando se trabalha com médias suavizadas ou janelas observação. Essa aproximação também facilita algumas inferências, principalmente em contextos comparativos. Aplicações semelhantes foram exploradas em modelagens de futebol por Baio e Blangiardo [1].

A formulação matemática do modelo é:

$$Y_{ijt}|\boldsymbol{X}_{ijt} \sim \mathcal{N}(\mu_{ijt}, \sigma^2) \tag{2.6}$$

$$\mu_{ijt} = u_i^{(\text{atk})} - u_j^{(\text{def})} + \beta_{\text{home}} \cdot \text{home}_{ijt}, \tag{2.7}$$

onde:

- Y_{ijt}: número de gols marcados pelo time i contra o time j na rodada t;
- $\boldsymbol{X}_{ijt}$: informação condicional sobre a partida do time i contra o time j na rodada t;
- μ_{ijt}: média esperada do número de gols;
- σ^2: variância do número de gols;
- β_{home}: efeito fixo associado ao mando de campo;
- home_{ijt}: variável indicadora (1 se o time i for mandante contra o time j na rodada t, 0 caso contrário);

- $u_i^{(atk)} \sim \mathcal{N}(0, \sigma^2_{atk})$: efeito aleatório de ataque do time i;
- $u_j^{(def)} \sim \mathcal{N}(0, \sigma^2_{def})$: efeito aleatório de defesa do time j.

Note que a formulação matemática do modelo Normal acima não possui um intercepto global α. Essa escolha foi feita *post-hoc*, com base na comparação das performances preditivas dos modelos com e sem intercepto.

2.3 Modelos Dinâmicos para número de gols

Até aqui, os modelos considerados assumem que as habilidades ofensivas e defensivas permanecem constantes ao longo do campeonato (e logo são apropriadamente denominados de modelos "estáticos"). O uso de modelos dinâmicos, por sua vez, permite que os fatores sejam atualizados conforme os jogos acontecem, incorporando informações de cada rodada.

A abordagem dinâmica foi formalizada pela primeira vez por Knorr-Held [5], que propuseram o uso de modelos hierárquicos dinâmicos em contextos de séries temporais estruturadas (como registros de mortalidade), e que podem então ser estendidos de maneira natural à modelagem de resultados esportivos. Dessa forma, o histórico da equipe no campeonato é constantemente reavaliado, possibilitando previsões mais precisas e adaptativas.

2.4 Modelos Dinâmicos para Previsão de Gols

A seguir, apresentamos a formulação matemática dos modelos utilizados para prever o número de gols em partidas de futebol, considerando uma estrutura dinâmica que evolui ao longo das rodadas do campeonato. Foram implementados dois modelos distintos: um com distribuição de Poisson e outro com distribuição Normal.

Ambos os modelos possuem uma estrutura similar à estrutura condicional do modelo estático dada em (2.1), porém aqui os efeitos ataque e defesa de cada time são permitidos variar com o tempo. Dessa forma, temos

$$g\big(\mathbb{E}[Y_{ijt}|\boldsymbol{X}_{ijt}]\big) = \alpha + u_{it}^{(atk)} - u_{jt}^{(def)}, \tag{2.8}$$

onde $u_{it}^{(atk)}$ e $u_{jt}^{(def)}$ são, respectivamente, o efeito ataque do time i e o efeito defesa do time j na rodada t.

Para governar a dinâmica dos efeitos ataque e defesa, supõe-se aqui que os processos estocásticos $(u_{it}^{(atk)})_{t=1}^{T}$ e $(u_{jt}^{(def)})_{t=1}^{T}$ tomem a forma de passeios aleatórios, isto é,

$$u_{it}^{(atk)} = u_{i,t-1}^{(atk)} + Z_{it}^{(atk)}, \qquad Z_{it}^{(atk)} \sim \text{ind. } \mathcal{N}(0, \sigma_{atk}^2), \tag{2.9}$$

$$u_{jt}^{(def)} = u_{j,t-1}^{(def)} + Z_{jt}^{(def)}, \qquad Z_{jt}^{(def)} \sim \text{ind. } \mathcal{N}(0, \sigma_{def}^2), \tag{2.10}$$

para todo i e j, inicializados em $u_{i1}^{(atk)} \sim \mathcal{N}(0, \sigma_{atk}^2)$ e $u_{j1}^{(def)} \sim \mathcal{N}(0, \sigma_{def}^2)$. Novamente assume-se que $(u_{it}^{(atk)})_{t=1}^{T}$ e $(u_{jt}^{(def)})_{t=1}^{T}$ sejam processos independentes entre si.

2.4.1 Modelo Poisson Dinâmico

O modelo Poisson Dinâmico é um análogo exato do modelo Poisson estático apresentado na Seção 2.2.1. Sua formulação matemática é dada por:

$$Y_{ijt} | \boldsymbol{X}_{ijt} \sim \text{Poisson}(\lambda_{ijt}) \tag{2.11}$$

$$\log(\lambda_{ijt}) = \alpha + u_{it}^{(\text{atk})} - u_{jt}^{(\text{def})} + \beta_{\text{home}} \cdot \text{home}_{ijt} \tag{2.12}$$

$$u_{it}^{(atk)} = u_{i,t-1}^{(atk)} + Z_{it}^{(atk)}, \qquad Z_{it}^{(atk)} \sim \text{ind. } \mathcal{N}(0, \sigma_{atk}^2) \tag{2.13}$$

$$u_{jt}^{(def)} = u_{j,t-1}^{(def)} + Z_{jt}^{(def)}, \qquad Z_{jt}^{(def)} \sim \text{ind. } \mathcal{N}(0, \sigma_{def}^2) \tag{2.14}$$

onde:

- Y_{ijt}: número de gols marcados pelo time i contra o time j na rodada t;
- $\boldsymbol{X}_{ijt}$: informação condicional sobre a partida do time i contra o time j na rodada t;
- λ_{ijt}: taxa média de gols esperada;
- α é o intercepto global;
- β_{home}: efeito fixo associado ao mando de campo;
- home_{ijt}: variável indicadora (1 se o time i for mandante contra o time j na rodada t, 0 caso contrário);
- $u_i^{(atk)} \sim \mathcal{N}(0, \sigma_{atk}^2)$: efeito aleatório de ataque do time i na rodada t;
- $u_j^{(def)} \sim \mathcal{N}(0, \sigma_{def}^2)$: efeito aleatório de defesa do time j na rodada t.

Completa-se a especificação do modelo Poisson Dinâmico sob o paradigma de inferência Bayesiano com as prioris para seus hiperparâmetros, que aqui são dadas por:

$$\sigma_{atk}^2 \overset{d}{=} \sigma_{def}^2 \sim \text{Cauchy}^{+}(0, 25)$$

$$\alpha \overset{d}{=} \beta_{\text{home}} \sim \mathcal{N}(0, 10)$$

onde $\text{Cauchy}^{+}(m, \gamma)$ denota uma distribuição Cauchy truncada em $\mathbb{R}^{+} := [0, +\infty)$ com parâmetro de locação m e de escala γ, e "$\overset{d}{=}$" denota igualdade em distribuição.

2.4.2 Modelo Normal Dinâmico

O modelo Normal Dinâmico também é um análogo do modelo Normal estático apresentado na Seção 2.2.3, e sua formulação matemática é dada por:

$$
\begin{aligned}
Y_{ijt}|\boldsymbol{X}_{ijt} &\sim \mathcal{N}(\mu_{ijt}, \sigma^2) && && (2.15)\\
\mu_{ijt} &= u_{it}^{(\text{atk})} - u_{jt}^{(\text{def})} + \beta_{\text{home}} \cdot \text{home}_{ijt} && && (2.16)\\
u_{it}^{(atk)} &= u_{i,t-1}^{(atk)} + Z_{it}^{(atk)}, && Z_{it}^{(atk)} \sim \text{ind. } \mathcal{N}(0, \sigma_{atk}^2) && (2.17)\\
u_{jt}^{(def)} &= u_{j,t-1}^{(def)} + Z_{jt}^{(def)}, && Z_{jt}^{(def)} \sim \text{ind. } \mathcal{N}(0, \sigma_{def}^2) && (2.18)
\end{aligned}
$$

onde:

- Y_{ijt}: número de gols marcados pelo time i contra o time j na rodada t;
- $\boldsymbol{X}_{ijt}$: informação condicional sobre a partida do time i contra o time j na rodada t;
- μ_{ijt}: média esperada do número de gols;
- σ^2: variância do número de gols;
- β_{home}: efeito fixo associado ao mando de campo;
- home_{ijt}: variável indicadora (1 se o time i for mandante contra o time j na rodada t, 0 caso contrário);
- $u_i^{(atk)} \sim \mathcal{N}(0, \sigma_{atk}^2)$: efeito aleatório de ataque do time i na rodada t;
- $u_j^{(def)} \sim \mathcal{N}(0, \sigma_{def}^2)$: efeito aleatório de defesa do time j na rodada t.

As prioris para os hiperparâmetros do Modelo Normal Dinâmico são dadas por

$$
\begin{aligned}
\sigma^2 \overset{d}{=} \sigma_{atk}^2 \overset{d}{=} \sigma_{def}^2 &\sim \text{Cauchy}^+(0, 25)\\
\beta_{\text{home}} &\sim \mathcal{N}(0, 10)
\end{aligned}
$$

e nota-se mais uma vez que o Modelo Normal Dinâmico, assim como sua versão estática, não possui um intercepto global α.

2.4.3 Observações

Ambos os modelos assumem que as habilidades ofensivas e defensivas evoluem ao longo do campeonato, o que permite capturar mudanças de desempenho dos times de maneira mais realista. Além disso, o efeito de mando de campo é mantido fixo ao longo da temporada, sendo representado por um único parâmetro global.

A estimação dos parâmetros dos modelos foi realizada por meio de amostragem MCMC (Markov Chain Monte Carlo), conforme implementado na linguagem `Stan`. Essa abordagem permite obter amostras da distribuição a posteriori dos parâmetros do modelo, como

as habilidades ofensiva e defensiva dos times ao longo das rodadas, o efeito do mando de campo e os desvios padrão associados à dinâmica temporal. A fim de garantir a identificabilidade dos efeitos dinâmicos, todos os $u_{it}^{(atk)}$ e $u_{jt}^{(def)}$ de uma mesma rodada t são centrados em suas médias correspondentes.

A partir das amostras obtidas via MCMC, são geradas as previsões para os gols e resultados de cada um jogos em cada uma das rodadas. Mais especificamente, toma-se a esperança a posteriori $\hat{Y}_{ijt} := \mathbb{E}[Y_{ijt}|\boldsymbol{X}_{ijt}]$ como estimador do número de gols feito pelo time i no time j na rodada t, e analogamente para $\hat{Y}_{jit}$.

2.5 Modelos Estáticos para previsão de Resultados

2.5.1 Modelo Logístico Multinomial

Empregado para prever diretamente o resultado final de uma partida (vitória, empate ou derrota) com base nas variáveis históricas e contextuais, o Modelo Logístico Multinomial considera a natureza categórica do desfecho e incorpora variações específicas dos times e rodadas, permitindo classificações probabilísticas dos resultados.

Para um jogo do time i contra o time j na rodada t, denote o resultado por R_{ijt}. Tem-se então que $R_{ijt} \in \{0, 1, 2\}$, onde o valor 0 corresponde à uma derrota ("L", do inglês *loss*), 1 corresponde à um empate ("D", do inglês *draw*) e 2 corresponde à uma vitória ("W", do inglês *win*). Sob o modelo Logístico Multinomial, a probabilidade de que R_{ijt} pertença à classe m é dada então por

$$P(R_{ijt} = m|\boldsymbol{X}_{ijt}) = \frac{\exp(\eta_{ijt}^m)}{\sum_{k=0}^{M} \exp(\eta_{ijt}^k)}, \quad m = 0, 1, M = 2, \tag{2.19}$$

onde $\eta_{ijt}^m = \alpha + u_i^{(atk)} - u_j^{(def)}$ é o preditor linear correspondente à classe m. Para garantir a identificabilidade do modelo, toma-se $\eta_{ijt}^0 = 0$ para todo i, j e t.

2.6 Critérios de Classificação dos Modelos

A avaliação da performance dos modelos foi feita com base na acurácia balanceada (*balanced accuracy*), uma métrica que considera a média das taxas de acerto de cada classe. Essa abordagem é ideal em situações onde as classes são desbalanceadas, como o caso de resultados esportivos, onde a frequência de vitórias, empates e derrotas pode oscilar bastante.

A acurácia balanceada calcula a média das taxas de acerto das classes individuais, garantindo que o desempenho do modelo não seja inflado por um bom desempenho em classes mais frequentes. Dessa forma, é possível calcular de forma mais precisa a capacidade do modelo prever vitórias (W), empates (D) e derrotas (L).

Para transformar as predições dos modelos para número de gols em resultados dos jogos, foram estabelecidos dois thresholds (limiares), τ_1 e τ_2, tais que $\tau_1 \leq \tau_2$. Esses limiares permitem ajustar a sensibilidade do modelo para cada categoria (especialmente onde a decisão é mais incerta, como nos empates), e esse ajuste permite reduzir os erros de classificação e melhorar a acurácia final do modelo.

Mais especificamente, defina $\Delta\hat{Y}_{ijt} := \hat{Y}_{ijt} - \hat{Y}_{jit}$ como a diferença entre o número de gols feitos pelo time i no time j e pelo time j no time i na rodada t. Temos então que:

- se $\Delta\hat{Y}_{ijt} \leq \tau_1$, o resultado é classificado como derrota;
- se $\tau_1 < \Delta\hat{Y}_{ijt} < \tau_2$, o resultado é classificado como empate;
- se $\Delta\hat{Y}_{ijt} \geq \tau_2$, o resultado é classificado como vitória.

Cada modelo foi avaliado tanto no conjunto de treinamento quanto no de teste. A comparação entre a performance em ambos os conjuntos permite verificar a capacidade de generalização dos modelos utilizados. A matriz de confusão foi utilizada para detalhar os acertos e erros por classe, e a acurácia balanceada foi analisada para cada tipo de resultado individualmente.

2.7 Análise de Resíduos

Após o ajuste do modelo, foi realizada uma análise de resíduos com o pacote DHARMa, uma ferramenta amplamente utilizada para diagnóstico de modelos de regressão generalizados e mistos. O DHARMa utiliza uma abordagem baseada em simulações para gerar resíduos padronizados, mesmo em modelos complexos, permitindo avaliações robustas de ajuste.

Foram utilizados resíduos do tipo PIT (*Probability Integral Transform*), que são obtidos simulando valores de resposta do modelo ajustado e transformando as distribuições empíricas em uma distribuição uniforme padronizada no intervalo [0, 1]. Essa abordagem permite detectar desvios sistemáticos em relação ao modelo ajustado, qualquer que seja a distribuição original dos dados.

Dois tipos de gráficos foram gerados:

- Histograma dos resíduos escalados (PIT): esse gráfico compara a densidade dos resíduos simulados com a distribuição uniforme ideal;
- QQplots Normais: obtidos aplicando a função quantil da distribuição Normal padrão $\Phi^{-1}(\cdot)$ aos resíduos PIT, transformando os em resíduos quantílicos e depois comparando seus quantis com o da $\mathcal{N}(0, 1)$.

Essa análise permitiu verificar a adequação da distribuição assumida para os erros do modelo e identificar eventuais desvios. Desvios da reta tracejada nos PITs ou da linha diagonal nos QQplots indicam não-normalidade e/ou presença de valores extremos.

3 Resultados

Distribuição de Gols: Mandante vs. Visitante

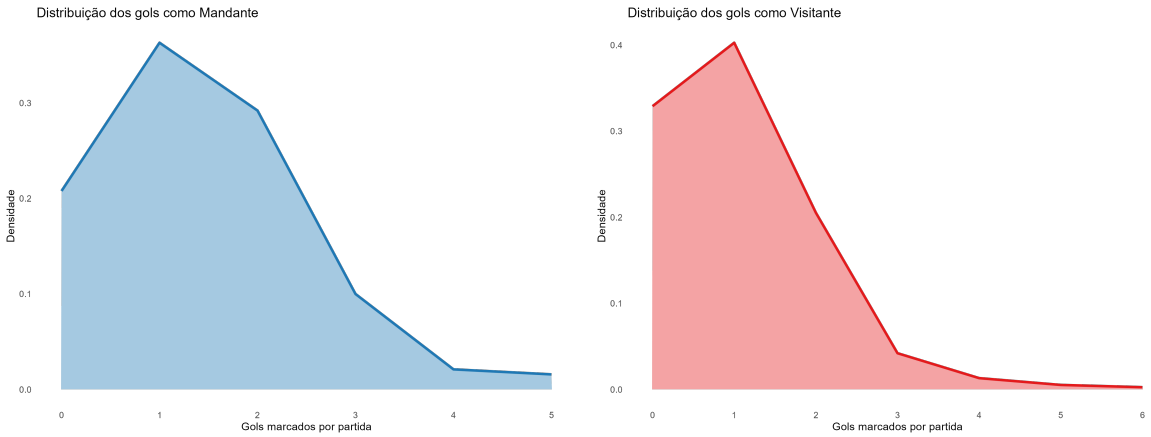


Figura 1 – Distribuição de gols marcados como mandante e visitante por equipe.

A Figura 1 de distribuição de gols mostra que os mandantes têm desempenho ofensivo superior: marcam mais gols e têm menos jogos zerados. O pico da distribuição ocorre em 1 gol, mas há boa frequência de 2 ou 3 gols. Já os visitantes marcam menos gols, com alta frequência de 0 gols e quedas acentuadas a partir de 2 gols. Esses padrões confirmam o impacto do mando de campo, justificando sua inclusão como variável nos modelos preditivos.

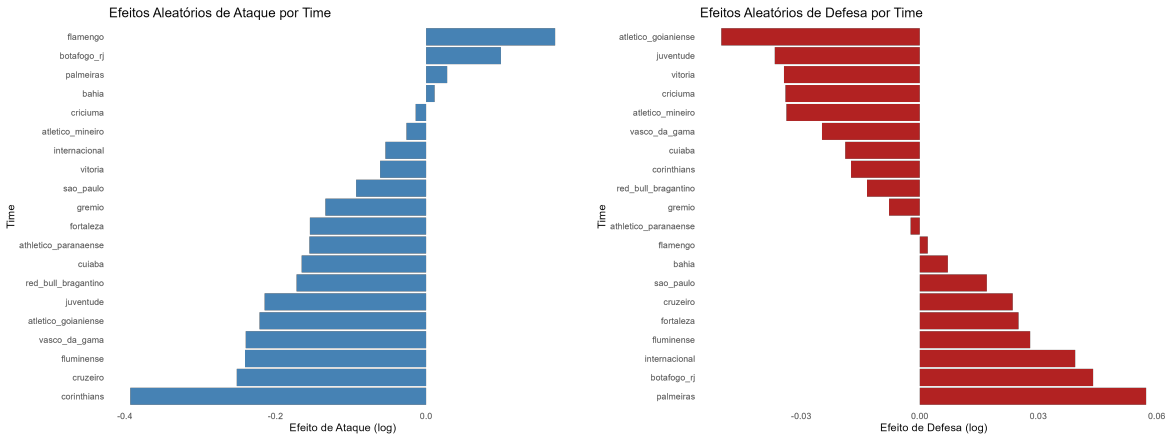


Figura 2 – Efeitos estimados de ataque (esquerda) e defesa (direita) por equipe.

Cada modelo estima, para cada time, dois parâmetros principais: o efeito de ataque, que representa a capacidade ofensiva da equipe, e o efeito de defesa, associado à sua capacidade defensiva. Esses fatores são extraídos a partir dos dados históricos e utilizados diretamente na modelagem para prever o número esperado de gols marcados (gf) e sofridos (ga) por cada time (Figura 2). No gráfico, valores mais altos de ataque indicam maior propensão a marcar gols, enquanto valores menores de defesa refletem maior vulnerabilidade defensiva. A combinação desses efeitos permite simular os resultados das partidas.

3.1 Modelos Estáticos

3.1.1 Modelo Normal

A Tabela 1 apresenta a matriz de confusão do modelo com distribuição Normal, utilizado para prever o número de gols marcados pelas equipes. O modelo foi avaliado com base em thresholds definidos para converter os valores contínuos em categorias de resultado: vitória (W), empate (D) e derrota (L).

Tabela 1 – Matriz de confusão do modelo Normal Estático.

Real \ Predito	**Derrota (L)**	**Empate (D)**	**Vitória (W)**
Derrota (L)	2	6	4
Empate (D)	1	5	5
Vitória (W)	2	4	11

O modelo baseado na distribuição Normal apresentou acurácia geral de **45,0%**, com destaque principalmente na previsão de vitórias, que foi a categoria com maior taxa de acertos. O modelo mostrou dificuldade em distinguir derrotas e empates, conforme evidenciado pelos erros nas respectivas células da matriz.

3.1.2 Modelo Poisson

Tabela 2 – Matriz de confusão do modelo Poisson estático.

Real \ Predito	**Derrota (L)**	**Empate (D)**	**Vitória (W)**
Derrota (L)	9	1	2
Empate (D)	6	3	2
Vitória (W)	4	6	7

A Tabela 2 apresenta a matriz de confusão baseada no modelo com distribuição Poisson, utilizado para prever o número de gols marcados pelas equipes. O principal destaque foi a alta taxa de acertos na previsão de derrotas **75,0%**. No entanto, a confusão entre empates e vitórias é evidente, o que ainda indica áreas de melhoria na capacidade de diferenciação entre categorias com margens mais estreitas de gols. Quanto à sua acurácia, o modelo se mostra levemente superior ao modelo anterior, com acurácia de **47,5%**.

3.1.3 Modelo Binomial Negativo

Tabela 3 – Matriz de confusão do modelo Binomial Negativo estático.

Real \ Predito	**Derrota (L)**	**Empate (D)**	**Vitória (W)**
Derrota (L)	9	1	2
Empate (D)	6	3	2
Vitória (W)	4	6	7

O modelo baseado na distribuição Binomial Negativa apresentou a mesma matriz de confusão e acurácia **47,5%** que o modelo Poisson, resultado explicado pelo parâmetro de sobredispersão θ estimado em zero. Isso indica que, para este conjunto de dados, não houve evidência de variabilidade extra além da prevista pelo modelo Poisson, e, portanto, a inclusão do parâmetro de sobredispersão não trouxe ganhos em termos de ajuste ou previsão dos resultados. Dessa forma, o modelo Binomial Negativo se comportou de maneira exatamente equivalente ao modelo Poisson, com bom desempenho na previsão de derrotas, mas dificuldades na classificação de empates e vitórias.

3.2 Modelo Logístico Multinomial

Tabela 4 – Matriz de confusão do modelo Logístico Multinomial.

Real \ Predito	**Derrota (L)**	**Empate (D)**	**Vitória (W)**
Derrota (L)	5	4	3
Empate (D)	3	3	5
Vitória (W)	5	1	11

A matriz de confusão do modelo Logístico Multinomial mostrou uma acurácia geral de **47,5%**, igual à obtida pelo modelo Poisson. O modelo multinomial apresentou boa sensibilidade na previsão de vitórias, acertando 11 casos, enquanto enfrentou dificuldades maiores para distinguir entre empates e derrotas, com várias confusões entre essas classes. Já o modelo Poisson mostrou um desempenho superior na identificação de derrotas, acertando 9 delas, mas com menor precisão para vitórias.

Ambos os tipos de modelos apresentaram dificuldades semelhantes na previsão de empates, que é o resultado mais desafiador. Essa complementaridade sugere que cada modelo possui pontos fortes específicos. Ainda assim, o desempenho apresentado pelos modelos é satisfatório considerando a complexidade inerente à previsão dos resultados em campeonatos equilibrados.

Tabela 5 – Resultados da rodada 32 - Probabilidades preditas e acertos do modelo Logístico Multinomial.

Time da Casa	**Time Oponente**	**PWIN**	**PDRAW**	**PLOSS**	**Real**	**Previsto**
Athletico-PR (12º)	Vitória (15º)	0.406	0.285	0.309	L	W
Atlético-GO (20º)	Atlético-MG (10º)	0.196	0.401	0.403	W	L
Bahia (7º)	São Paulo (6º)	0.363	0.304	0.332	L	W
Botafogo (1º)	Vasco da Gama (9º)	0.492	0.258	0.250	W	W
Corinthians (16º)	Palmeiras (2º)	0.185	0.399	0.415	W	L
Cruzeiro (8º)	Flamengo (4º)	0.301	0.341	0.358	L	L
Fluminense (14º)	Grêmio (11º)	0.395	0.285	0.320	D	W
Internacional (5º)	Criciúma (13º)	0.374	0.336	0.290	W	W
Juventude (18º)	Fortaleza (3º)	0.203	0.404	0.393	L	D
Bragantino (17º)	Cuiabá (19º)	0.338	0.344	0.317	D	D

Na 32ª rodada do campeonato, o modelo previu corretamente 4 das 10 partidas, resultando em uma acurácia de 40% ao considerar a classe de maior probabilidade ajustada

como previsão final.

Os acertos ocorreram, em geral, em jogos com disparidade clara entre as equipes, como:

- **Botafogo vs. Vasco da Gama**, com favoritismo expressivo do mandante;
- **Internacional vs. Criciúma**, onde o time gaúcho confirmou sua superioridade;
- **Cruzeiro vs. Flamengo**, um confronto equilibrado, mas com previsão e resultado alinhados.

Por outro lado, os erros ocorreram majoritariamente em situações de equilíbrio, onde as probabilidades preditas entre as três classes (vitória, empate e derrota) estavam bastante próximas. Um bom exemplo disso foi o jogo entre Red Bull Bragantino (17º) e Cuiabá (19º), no qual as probabilidades foram 33,8% para vitória, 34,4% para empate e 31,7% para derrota — um cenário típico de alta incerteza, mas que, mesmo assim, o modelo conseguiu acertar o empate.

Além disso, a rodada contou com algumas "zebras", isto é, quando os resultados contrariaram fortemente o favoritismo previsto. Destaque para:

- Atlético-GO (20º) vencendo o Atlético-MG (10º), apesar de ter apenas 19,6% de probabilidade de vitória, frente a mais de 40% para derrota;
- Corinthians (16º) vencendo o Palmeiras (2º), em confronto onde o modelo atribuía apenas 18,5% de chance de vitória ao time da casa.

Esses desvios ressaltam o aspecto imprevisível do futebol, onde fatores não modelados podem influenciar fortemente o resultado final.

3.3 Modelos Dinâmicos

3.3.1 Modelo Normal

Tabela 6 – Matriz de confusão do modelo Normal dinâmico.

Real \ Predito	**Derrota (L)**	**Empate (D)**	**Vitória (W)**
Derrota (L)	9	3	0
Empate (D)	5	1	5
Vitória (W)	3	3	11

O modelo Normal dinâmico apresenta uma melhora clara em relação ao modelo Normal estático, alcançando uma acurácia geral de **52,5%**, superior aos **45,0%** do modelo

estático. O destaque fica para a previsão de vitórias, que teve um salto considerável na acurácia, chegando a **67,8%**, o que demonstra um ganho importante na capacidade de identificar resultados positivos. As classes empate e derrota ainda apresentam acurácias menores, o que mostra que esses resultados exigem maior refinamento, mas o avanço trazido pelo modelo dinâmico é evidente. Essa comparação indica que incorporar dinamicidade aos modelos contribui para melhores previsões, principalmente em categorias com padrões mais definidos.

Tabela 7 – Acurácia por classe de resultado para o modelo Normal dinâmico.

Classe	**Acurácia**
Vitória (W)	67,8%
Empate (D)	43,6%
Derrota (L)	49,3%

3.3.2 Modelo Poisson

Tabela 8 – Matriz de confusão do modelo Poisson dinâmico.

Real \ Predito	**Derrota (L)**	**Empate (D)**	**Vitória (W)**
Derrota (L)	7	4	1
Empate (D)	4	5	2
Vitória (W)	2	3	12

A Tabela 8 mostra que o modelo Poisson Dinâmico alcançou uma acurácia de **60%**, superando **47,5%**, os obtidos com o modelo estático. Observa-se uma melhora consistente na capacidade preditiva para todas as classes.

Tabela 9 – Acurácia por classe de resultado do modelo Poisson dinâmico.

Classe	**Acurácia**
Vitória (W)	70,6%
Empate (D)	45,5%
Derrota (L)	58,3%

A previsão de vitórias teve o melhor desempenho, com **70,6%** de acertos, indicando que o modelo é bastante eficiente em capturar padrões associados a resultados positivos. A classe derrota também apresentou boa performance, com acurácia de **58,3%**, superior à

do modelo estático, que era de aproximadamente **45,0%**. Já a categoria de empates, tradicionalmente a mais difícil de prever, atingiu **45,5%**, mostrando leve avanço em relação à versão estática, embora continue sendo a classe com maior grau de incerteza.

3.4 Análise de Resíduos

3.4.1 Modelos Estáticos

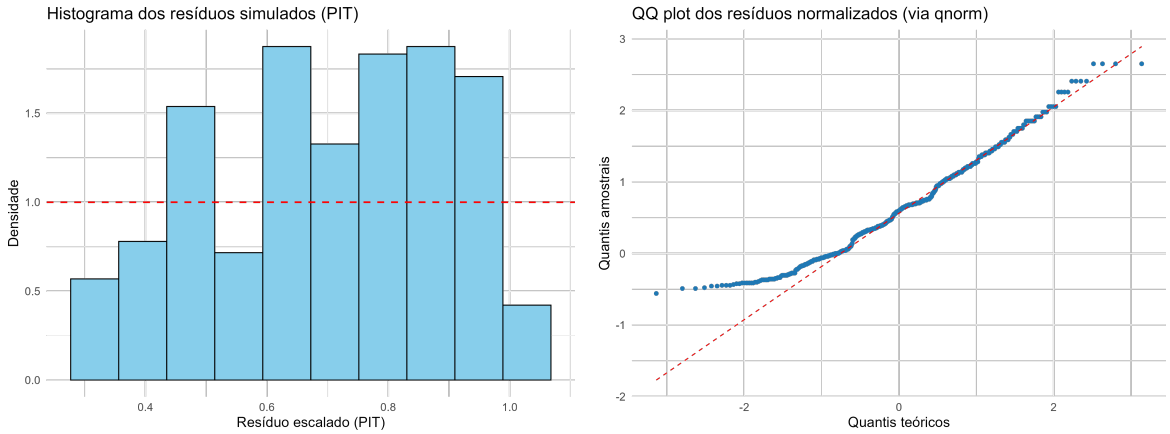


Figura 3 – Análise de resíduos do modelo Normal estático.

Para o modelo Normal estático, o histograma dos resíduos simulados (PIT) mostra concentração excessiva no centro da distribuição, com deficiência nas extremidades, o que indica que o modelo subestima a variabilidade dos dados. O QQ plot reforça esse padrão, com desvios claros da linha de referência, especialmente nas caudas. Esses resultados sugerem que a suposição de normalidade não é adequada para dados de contagem como gols.

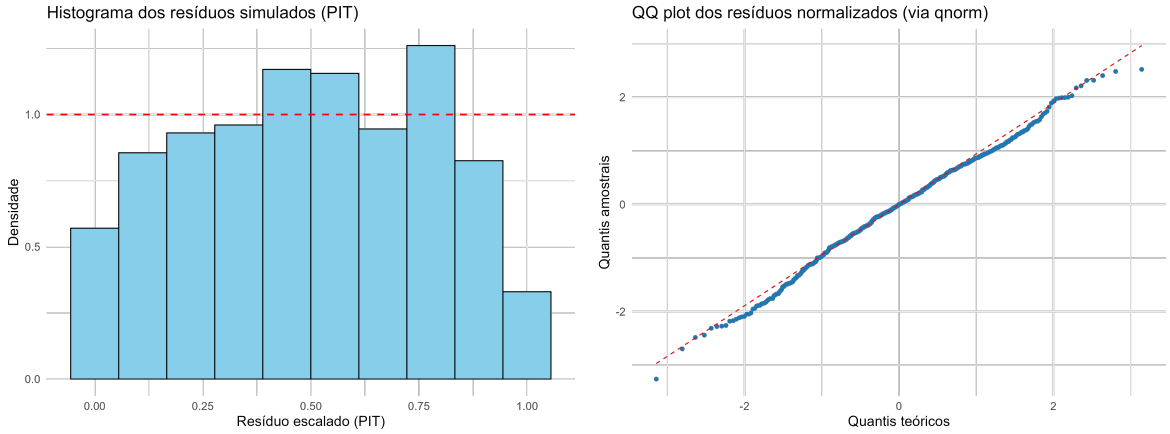


Figura 4 – Análise de resíduos do modelo Poisson estático.

Por outro lado, para o modelo Poisson estático, o histograma dos resíduos mostra aproximação razoável da densidade uniforme esperada, embora com leve inclinação à direita. O QQ plot apresenta bom alinhamento com a linha teórica, com pequenas discrepâncias nos extremos. O modelo Poisson apresenta desempenho superior ao Normal, mas ainda é limitado por assumir variância igual à média, o que pode não refletir a natureza dos dados observados.

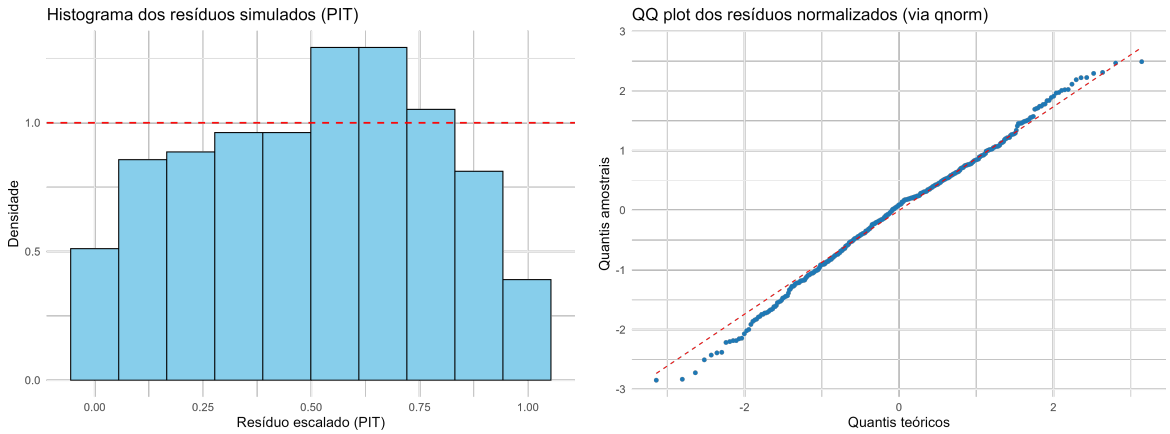


Figura 5 – Análise de resíduos do modelo Binomial Negativo.

Por fim, para o modelo Binomial Negativo estático, os resíduos simulados são bem distribuídos, com o histograma próximo da densidade uniforme ideal e QQ plot bem aderente à linha normal teórica. Esse bom desempenho reflete a maior flexibilidade do modelo Binomial Negativa, que acomoda a sobredispersão dos dados de contagem, sendo, portanto, o modelo com melhor ajuste entre os avaliados.

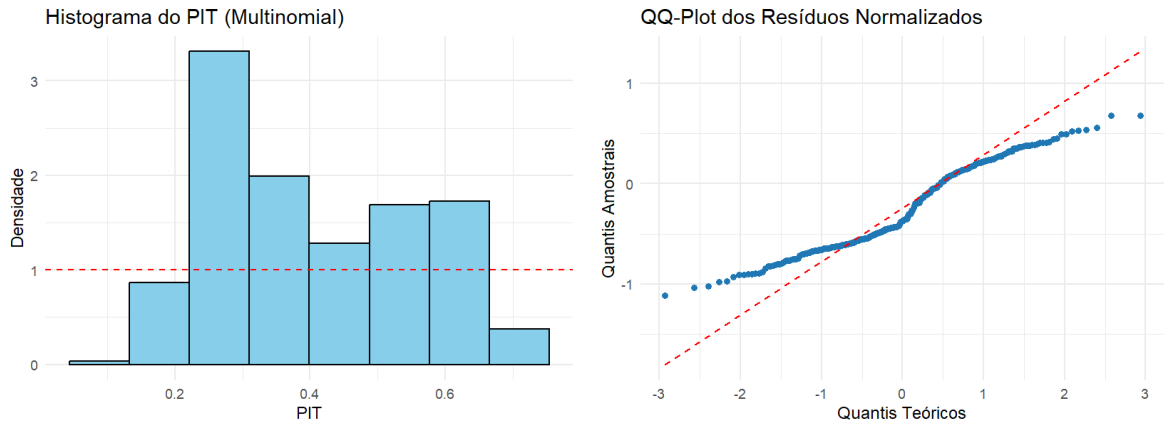


Figura 6 – Análise de resíduos do modelo Poisson Dinâmico.

O histograma PIT do modelo Logístico exibe uma distribuição próxima da uniforme, com densidade equilibrada entre 0 e 1, sugerindo bom ajuste. O QQ Plot confirma

essa aderência, com resíduos alinhados à linha teórica, exceto por pequenos desvios nos extremos. O modelo Logístico demonstra flexibilidade para capturar a variabilidade dos dados, sendo uma alternativa robusta para variáveis binárias ou categóricas.

3.4.2 Modelos Dinâmicos

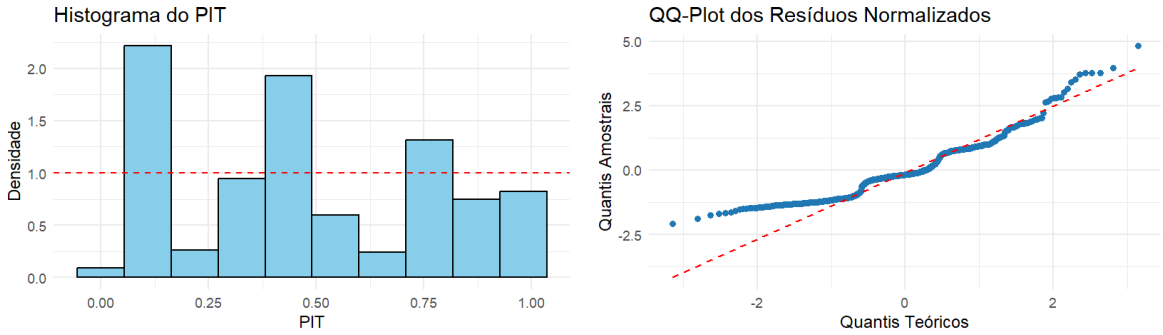


Figura 7 – Análise de resíduos do modelo Normal Dinâmico.

O histograma PIT revela concentração excessiva no centro e deficiência nas extremidades, indicando que o modelo subestima a variabilidade dos dados. O QQ Plot confirma esse padrão, com desvios sistemáticos da linha teórica, especialmente nas caudas. Os resíduos exibem caudas mais leves que o esperado para uma normal, sugerindo que a suposição de normalidade é inadequada para dados deste tipo.

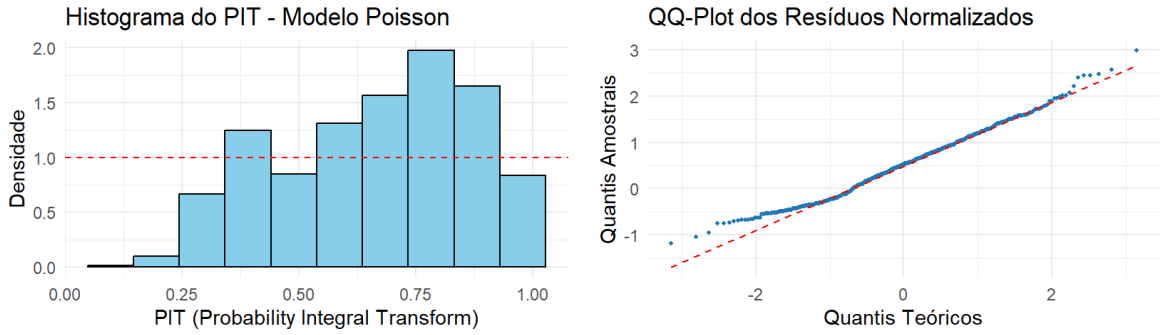


Figura 8 – Análise de resíduos do modelo Poisson Dinâmico.

O modelo Poisson apresenta um histograma PIT com distribuição assimétrica, concentrando densidade em valores baixos PIT < 0.5 e evidenciando subdispersão. O QQ Plot mostra resíduos com desvios acentuados nos quantis superiores.

4 Conclusão

O presente trabalho teve como objetivo avaliar a capacidade de modelos estatísticos em prever os resultados do Campeonato Brasileiro de Futebol - Série A, a partir de dados históricos das partidas.

Inicialmente, foram utilizados Modelos Lineares Generalizados Mistos (GLMMs) a fim de modelar o número de gols marcados por cada equipe, realizando testes com diferentes distribuições (Normal, Poisson e Binomial Negativa), com intuito de identificar aquela que melhor se ajustasse à natureza dos dados observados.

Em uma etapa posterior, adotou-se uma abordagem mais flexível por meio de modelos dinâmicos que incorporaram variações temporais nos fatores de defesa e ataque de cada equipe. Essa estrutura permite um melhor acompanhamento do desempenho de cada equipe ao longo do campeonato. Nesse contexto, foram testadas as distribuições Normal e Poisson.

De modo geral, os resultados indicaram limitações dos modelos na classificação da classe empate, evidenciando um desafio comum em problemas de previsão no futebol, dado seu caráter altamente equilibrado. Por fim, a comparação entre os modelos revelou as vantagens e limitações de cada abordagem. Enquanto os GLMs se destacam pela facilidade de implementação, interpretação e menor custo computacional, eles apresentam limitações na capacidade preditiva. Já os modelos dinâmicos possuem maior capacidade preditiva ao capturar a evolução temporal de desempenho das equipes ao longo de cada partida.

Como próximos passos, propõe-se a construção de uma abordagem híbrida, combinando os pontos fortes de cada técnica por meio de métodos de ensemble. Essa estratégia visa integrar a interpretabilidade dos GLMs com a capacidade preditiva dos modelos dinâmicos, utilizando técnicas modernas de Machine Learning para explorar padrões mais complexos e, assim, alcançar previsões mais robustas e eficazes.

Bibliografia

[1] Gianluca Baio e Marta Blangiardo. "Bayesian hierarchical model for the prediction of football results". Em: *Journal of Applied Statistics* 37.2 (2010), pp. 253–264.

[2] Brasil. *Lei nº 14.790, de 29 de dezembro de 2023*. `https://www2.camara.leg.br/legin/fed/lei/2023/lei-14790-29-dezembro-2023-795206-publicacaooriginal-170749-pl.html`. Aprova a regulamentação das apostas de quota fixa no Brasil. 2023.

[3] Andreas Groll. "Predicting outcomes in balanced football leagues: challenges and approaches". Em: *Journal of Sports Analytics* 4.3 (2018), pp. 205–218.

[4] Joseph M Hilbe. *Negative Binomial Regression*. 2ª ed. Cambridge University Press, 2011.

[5] Leonhard Knorr-Held. "Bayesian modelling of inseparable space-time variation in disease risk". Em: *Statistics in Medicine* 19.17-18 (2000), pp. 2555–2567.

[6] Peter McCullagh e John A Nelder. *Generalized Linear Models*. 2ª ed. Chapman e Hall/CRC, 1989.

[7] Carlos R. Padilha. "Incorporating contextual variables in football match outcome prediction". Em: *Anais do Congresso Brasileiro de Estatística Aplicada*. São Paulo, Brasil, 2022.

[8] José Carlos Silva. "Análise do futebol no Brasil como um fenômeno sociocultural". Em: *Revista Digital - Buenos Aires* 13.159 (2011). URL: `https://www.efdeportes.com/efd159/futebol-como-um-fenomeno-sociocultural.htm`.

A Código-Fonte R

Disponível no GitHub: github.com/mateusaguilar