UNIVERSIDADE FEDERAL DE MINAS GERAIS
Instituto de Ciências Exatas
Departamento de Estatística

Matheus Morgado Maia

Um estudo preditivo de modelos probabilísticos de futebol aplicado à Premier League

Belo Horizonte
2025
Matheus Morgado Maia

UM ESTUDO PREDITIVO DE MODELOS PROBABILÍSTICOS DE FUTEBOL APLICADO À PREMIER LEAGUE

Monografia apresentada ao programa de Graduação em Estatística da Universidade Federal de Minas Gerais, como requisito parcial para obtenção do título de Bacharel em Estatística.

Orientação: Uriel Moreira Silva

Belo Horizonte
2025

Declaro ter ciência do envio desse Relatório Final na data de hoje, 18/07/2025, pelo aluno Matheus Morgado Maia.

Documento assinado digitalmente
URIEL MOREIRA SILVA
Data: 18/07/2025 09:31:48-0300
Verifique em https://validar.iti.gov.br

RESUMO

Nos últimos anos, a crescente disponibilidade de dados e o avanço das técnicas estatísticas de previsão têm impulsionado a sua aplicação em diversas áreas, como a medicina, a indústria e os esportes. No contexto do futebol, um dos esportes mais populares e acompanhados no mundo, a previsão de resultados tem despertado particular interesse entre analistas, casas de apostas e adeptos. No entanto, prever o desfecho de uma partida é uma tarefa complexa, influenciada por inúmeros fatores técnicos, táticos e situacionais.

Apesar do crescente interesse, ainda é limitada a quantidade de estudos acadêmicos voltados à aplicação de técnicas de Previsão no futebol, especialmente quando se trata de modelagens interpretáveis e replicáveis. Este trabalho tem como objetivo aplicar técnicas de regressão logística binária combinadas com a abordagem One-vs-Rest (OVR) para prever os resultados dos jogos da Premier League 2023/2024. A previsão foi realizada de forma categórica (vitória, empate ou derrota) por meio da construção de três modelos binários distintos, um para cada possível resultado, utilizando a metodologia OVR.

Foram utilizados dados estatísticos das partidas e métricas derivadas com o intuito de aumentar o poder preditivo dos modelos. O desempenho das classificações foi avaliado com base em métricas como acurácia, matriz de confusão, ROC-AUC e F1-score, permitindo uma comparação direta entre os três modelos OVR. Como resultado, foi possível desenvolver uma solução preditiva eficiente, que atingiu resultados competitivos em termos de acerto, contribuindo para o avanço do uso de métodos interpretáveis na previsão de partidas de futebol.

ABSTRACT

In recent years, the growing availability of data and the advancement of statistical forecasting techniques have driven their application across various fields, such as medicine, industry, and sports. In the context of football — one of the most popular and widely followed sports in the world — result prediction has gained particular interest among analysts, betting markets, and fans. However, forecasting the outcome of a match is a complex task, influenced by numerous technical, tactical, and situational factors.

Despite the increasing interest, academic studies focused on the application of predictive techniques in football remain limited, especially those involving interpretable and replicable models. This study aims to apply binary logistic regression techniques combined with the One-vs-Rest (OvR) strategy to predict match outcomes in the 2023/2024 Premier League season. The prediction was performed categorically (win, draw, or loss) through the construction of three distinct binary models, one for each possible outcome, using the OvR methodology.

Statistical match data and derived metrics were used to enhance the predictive power of the models. The classification performance was evaluated based on metrics such as accuracy, confusion matrix, ROC-AUC, and F1-score, allowing for a direct comparison between the three OvR models. As a result, it was possible to develop an efficient predictive solution that achieved competitive accuracy, contributing to the advancement of interpretable methods in football match forecasting.

1. INTRODUÇÃO

1.1 Cenário

O futebol é um dos esportes mais populares do mundo. Sendo assim, a percepção do jogo e a previsão dos resultados tornaram-se temas de interesse para diversos públicos, incluindo fãs, apostadores, treinadores e a comunicação social. Para atingir esse objetivo, é necessário considerar uma grande quantidade de fatores que influenciam diretamente os resultados das partidas. Entre eles, destaca-se o desempenho recente das equipes no campeonato, que fornece indícios relevantes sobre sua forma atual, consistência ofensiva e solidez defensiva (SILVA, 2011).

Esses fatores tornam a tarefa de prever o desfecho de uma partida particularmente desafiadora. Mesmo para especialistas como jornalistas, comentadores e treinadores, a previsão de um resultado com exatidão permanece uma tarefa complexa.

Nesse contexto, os modelos estatísticos surgem como ferramentas poderosas para apoiar esse tipo de análise. Técnicas como a regressão logística binária têm sido amplamente utilizadas na modelagem de problemas classificatórios, como a previsão de vitórias, empates e derrotas em competições esportivas. Esse tipo de modelo permite estimar a probabilidade de ocorrência de um determinado resultado com base em variáveis explicativas extraídas de dados históricos, como número de vitórias, gols marcados, posse de bola, entre outros indicadores de desempenho.

Além disso, estratégias como a abordagem One-vs-Rest (OvR) possibilitam transformar o problema multiclasse (típico na previsão de resultados com três possíveis categorias) em um conjunto de problemas binários mais simples e interpretáveis. A utilização dessas técnicas estatísticas permite uma análise mais estruturada e baseada em evidências, favorecendo a construção de modelos preditivos com bom desempenho e capacidade generalizável (RIMAL et al., 2024).

1.2 Objetivo

Atualmente, há uma enorme quantidade de dados disponíveis sobre partidas de futebol, incluindo estatísticas de jogos, desempenho individual de jogadores, informações sobre as equipes, treinamentos, entre outros. No entanto, ainda é limitada a informação pública sobre como os clubes utilizam esses dados de forma estratégica, embora seja evidente que muitos já compreendem o valor da análise preditiva para obter vantagem competitiva (PADILHA, 2022).

Embora existam diversas abordagens para prever os resultados de partidas (como análise de odds, modelos baseados em ratings ou inteligência artificial) este estudo se concentra especificamente na análise do desempenho prévio das equipes ao longo da

temporada, considerando variáveis como resultado dos jogos anteriores, mando de campo e consistência ao longo das rodadas.

O principal objetivo desta dissertação é desenvolver um estudo empírico baseado em modelos estatísticos de classificação, com foco na previsão de resultados de partidas da Premier League 2023/2024. O problema foi tratado como uma tarefa de classificação multiclasse, onde cada jogo é categorizado em uma das três classes: vitória, empate ou derrota. Para isso, foi adotada a metodologia One-vs-Rest (OvR), que transforma o problema em três classificações binárias, cada uma modelando separadamente uma das categorias contra as demais.

A modelagem foi conduzida com base na regressão logística binária, por ser uma técnica estatística robusta, amplamente utilizada em problemas de classificação, e por fornecer interpretações claras sobre a influência de cada variável preditora. O desenvolvimento do modelo seguiu um processo iterativo, com diferentes fases de limpeza, preparação e transformação dos dados, criação de variáveis derivadas e testes com diferentes estratégias de codificação.

Durante o projeto, foram feitas avaliações comparativas entre os três modelos binários (vitória, empate, derrota), considerando métricas como acurácia, precisão, sensibilidade, F1-score e AUC. Ao final, selecionou-se o conjunto de variáveis e estrutura que apresentou os melhores resultados. Todo o estudo foi implementado utilizando a linguagem R, com apoio de pacotes estatísticos e de machine learning voltados para modelagem, avaliação e visualização de dados.

1.3 Estrutura do Documento

Este trabalho está organizado em cinco capítulos: Introdução, Revisão da Literatura, Análise e Preparação dos Dados, Modelagem Estatística e Conclusão.

No Capítulo 2 – Revisão da Literatura, é apresentada uma contextualização teórica sobre modelos estatísticos de classificação, com foco na regressão logística binária e em estratégias de abordagem multiclasse, como a One-vs-Rest (OvR). Também são discutidos trabalhos acadêmicos relacionados à previsão de resultados esportivos, especialmente no futebol.

O Capítulo 3 – Análise e Preparação dos Dados descreve o processo de obtenção, tratamento e transformação dos dados utilizados no estudo. São detalhados os critérios de seleção das variáveis, a construção de indicadores derivados a partir do desempenho anterior das equipes e o tratamento de aspectos como o fator de mando de campo.

No Capítulo 4 – Modelagem Estatística, são apresentados os modelos de regressão logística binária utilizados para prever os resultados das partidas da Premier League

2023/2024, seguindo a estratégia One-vs-Rest. São detalhados os procedimentos de treinamento, validação, avaliação dos modelos, além das métricas de desempenho utilizadas para comparar os resultados.

Por fim, o Capítulo 5 – Conclusão reúne as principais contribuições do estudo, analisa os resultados obtidos e apresenta sugestões para trabalhos futuros que possam expandir ou complementar esta pesquisa.

2. REVISÃO DA LITERATURA

A modelagem preditiva de resultados esportivos tem ganhado destaque com o avanço das técnicas de aprendizado de máquina e o aumento da disponibilidade de dados detalhados sobre competições. Neste contexto, a regressão logística, em suas diversas formas, tem se mostrado uma ferramenta poderosa e interpretável para previsão de resultados categóricos, como vitórias, empates e derrotas no futebol.

2.1 Fundamentos da Regressão Logística

A regressão logística é uma técnica estatística amplamente utilizada para modelar a probabilidade de ocorrência de um evento binário, ou seja, quando a variável resposta assume dois possíveis resultados (CORDEIRO et al., 2024). Diferente da regressão linear, que prevê valores contínuos, a regressão logística estima a probabilidade de um evento ocorrer, garantindo que os valores previstos estejam entre 0 e 1.

Matematicamente, a regressão logística modela a relação entre uma variável dependente binária Y e um conjunto de variáveis independentes $\boldsymbol{X} = (X_1, X_2, \dots, X_p)$ por meio da função logística:

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p)}}$$

Essa equação pode ser reescrita em termos da função logito (log-odds):

$$\log\left(\frac{P(Y = 1 \mid \boldsymbol{X})}{1 - P(Y = 1 \mid \boldsymbol{X})}\right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$$

onde:

- β_0 é o intercepto do modelo;
- β_j são os coeficientes associados às variáveis independentes X_j , $j = 1, \dots p$.

No caso específico do problema de previsão de resultados de futebol tratado nessa monografia, temos

$$Y_{ijt}|\boldsymbol{X}_{ijt} \sim Bernoulli(\pi_{ijt})$$

$$\log\left(\frac{\pi_{ijt}}{1 - \pi_{ijt}}\right) = \beta_0 + \sum_{k=1}^{19} \beta_k A_i^k + \sum_{l=20}^{40} \beta_l D_j^{l-19}$$

onde Y_{ijt} é o resultado do jogo do time i contra o time j na rodada t, $\pi_{ijt} \coloneqq P\left(Y_{ijt} = 1 \middle| \boldsymbol{X}_{ijt}\right)$ e $\boldsymbol{X}_{ijt} \coloneqq \left(A_i^1, A_i^2, \dots A_i^{19}, D_j^1, D_j^2, \dots, D_j^{20}\right)$, em que A_i^k é uma indicadora do time k (isto é, tomando valor igual a 1 se $k = i$ e 0 caso contrário) e D_j^l é uma indicadora do time l (isto é, tomando valor igual a 1 se $l = j$ e 0 caso contrário).

A estrutura acima foi adotada de modo que cada A_i^k represente o *fator ataque* do time k correspondente, isto é, a contribuição ofensiva média do time para o resultado Y_{ijt}. De maneira análoga, D_j^l representa o *fator defesa* do time l, isto é, a contribuição defensiva média do time para o resultado Y_{ijt}. O resultado de um jogo específico Y_{ijt} (e que para fins de estimação é classificado de maneira binária; veja abaixo) é então modelado como uma função do fator ofensivo do time i e do fator defensivo do time j. Naturalmente, afim de possibilitar a identificação das estimativas do modelo, um dos 20 times tem que servir como categoria de referência para os fatores ataque A_i^k (e logo seu fator ataque será o próprio intercepto β_0), mas note que uma vez que isso é feito os fatores defesa D_j^l não precisam de uma referência.

A estimação dos parâmetros $\boldsymbol{\beta} \coloneqq \left(\beta_0, \beta_1, \dots, \beta_p\right)$ é geralmente realizada por meio do método da máxima verossimilhança, que busca os valores que maximizam a probabilidade de observar os dados amostrais.

Conforme destacado por Paula (2024), a regressão logística é particularmente útil quando se deseja interpretar os efeitos das variáveis explicativas sobre a probabilidade de ocorrência de um evento, além de permitir a inclusão de variáveis categóricas e contínuas no modelo.

2.2 Estratégia One-vs-Rest (OvR) para Classificação Multiclasse

Em problemas de classificação multiclasse, onde a variável resposta pode assumir mais de duas categorias, uma abordagem comum é decompor o problema em múltiplas classificações binárias. A estratégia One-vs-Rest (OvR), também conhecida como One-vs-All, consiste em ajustar um modelo binário para cada classe, considerando-a como a classe positiva e todas as demais como negativas (RIMAL et al., 2024)..

Por exemplo, em um problema com três classes: vitória, empate e derrota, seriam ajustados três modelos:

1. Modelo 1: Vitória vs. [Empate, Derrota]

2. Modelo 2: Empate vs. [Vitória, Derrota]

3. Modelo 3: Derrota vs. [Vitória, Empate]

Cada modelo estima a probabilidade de uma observação pertencer à classe positiva. A classe final atribuída à observação é aquela cujo modelo correspondente apresenta a maior probabilidade predita.

A principal vantagem do OvR é sua simplicidade e a possibilidade de utilizar algoritmos de classificação binária bem estabelecidos. Além disso, permite uma interpretação mais direta dos fatores que influenciam cada classe específica. No entanto, uma limitação é que as probabilidades estimadas pelos diferentes modelos podem não ser calibradas entre si, já que cada modelo é ajustado independentemente.

Ainda assim, o OvR tem sido amplamente utilizado na literatura por sua interpretabilidade, eficiência e facilidade de implementação. Em contextos esportivos, em que há interesse em compreender separadamente os fatores que aumentam a chance de vitória, empate ou derrota, o OvR permite análises direcionadas e tomadas de decisão mais estratégicas.

2.3 Comparação entre Estratégias de Classificação Multiclasse

Além do OvR, existem outras estratégias para lidar com problemas de classificação multiclasse. A tabela a seguir apresenta uma comparação entre as principais abordagens:

Estratégia	Número de Modelos	Complexidade Computacional	Interpretação	Calibração de Probabilidades
One-vs-Rest (OvR)	*K*	Baixa	Alta	Pode ser inconsistente
One-vs-One (OvO)	*K(K – 1)/2*	Média	Média	Melhor que OvR
Multinomial	1	Alta	Baixa	Consistente

onde K representa o número de classes.

A escolha da estratégia depende de diversos fatores, incluindo o número de classes, o tamanho do conjunto de dados, a necessidade de interpretabilidade e a capacidade

computacional disponível. No contexto deste estudo, a estratégia OvR foi escolhida devido à sua simplicidade e à facilidade de interpretação dos resultados, especialmente relevante para a análise de resultados de partidas de futebol.

2.4 Avaliação de Desempenho: Curva ROC, AUC e Cutoff de Youden

A avaliação de modelos de classificação exige métricas que reflitam não apenas a acurácia geral, mas também a capacidade do modelo em distinguir entre as classes. A curva ROC (Receiver Operating Characteristic) é amplamente utilizada para essa finalidade, pois ilustra a relação entre a taxa de verdadeiros positivos (sensibilidade) e a taxa de falsos positivos (1 - especificidade) para diferentes valores de cutoff.

A área sob a curva ROC (AUC – Area Under the Curve) é uma medida global da performance do modelo: quanto mais próxima de 1, melhor a capacidade discriminante. Um AUC de 0,5 indica um modelo que classifica aleatoriamente.

Para a determinação do cutoff ideal, foi utilizado o índice de Youden, definido como:

$$J = Sensibilidade + Especificidade - 1$$

Esse índice busca o ponto de corte que maximize simultaneamente a sensibilidade e a especificidade, sendo especialmente útil quando os custos dos erros de classificação são semelhantes entre as classes (AZNAR-GIMENO et al., 2023).

2.5 Aplicações da Regressão Logística e OvR em Previsão de Resultados Esportivos

A previsão de resultados esportivos, como partidas de futebol, é uma área que se beneficia significativamente da aplicação de modelos estatísticos. A regressão logística, em particular, tem sido amplamente utilizada para modelar a probabilidade de vitória, empate ou derrota de uma equipe com base em variáveis como desempenho anterior, vantagem de jogar em casa, estatísticas de jogadores, entre outros.

A estratégia OvR permite que cada resultado possível seja modelado separadamente, oferecendo insights específicos sobre os fatores que influenciam cada tipo de resultado. Por exemplo, um modelo pode revelar que a vantagem de jogar em casa aumenta significativamente a probabilidade de vitória, enquanto outro pode indicar que a ausência de jogadores-chave aumenta a probabilidade de derrota.

É importante ressaltar que, como as frequências de cada resultado não são as mesmas, o problema de classificação tratado aqui é desbalanceado. Como consequência, para

a condução do OvR, foi necessária ponderar a probabilidade estimada por cada regressão logística pelo inverso da frequência relativa da classe correspondente, levando ao que pode ser denominado como OvR com Cost-Sensitive Learning (ZHOU; LIU, 2010). Esse procedimento evita que o desbalaceamento entre as classes possa distorcer as predições finais e favorecer as classes mais frequentes.

2.6 Considerações Finais

A regressão logística, aliada à estratégia One-vs-Rest, oferece uma abordagem robusta e interpretável para problemas de classificação multiclasse, como a previsão de resultados de partidas de futebol. Sua capacidade de lidar com diferentes tipos de variáveis e de fornecer probabilidades estimadas para cada classe torna-a uma ferramenta valiosa para analistas e pesquisadores na área esportiva.

3. Preparação dos Dados

A qualidade e consistência dos dados utilizados exercem papel fundamental na construção de modelos preditivos robustos e interpretáveis. Neste trabalho, os dados analisados referem-se à temporada 2023/2024 da Premier League, principal competição de futebol da Inglaterra. A base original, em formato .csv, foi carregada para o ambiente de desenvolvimento R, utilizando funções de leitura e manipulação do pacote tidyverse. Essa base contém, para cada rodada (semana) da competição, informações essenciais sobre os confrontos disputados, incluindo o nome das equipes envolvidas (mandante e visitante), o placar final da partida e algumas métricas de desempenho.

3.1 Estruturação inicial e transformação simétrica da base

Após o carregamento dos dados, a primeira etapa consistiu na ordenação cronológica das partidas com base na variável Wk (semana), a fim de preservar a integridade temporal das observações. Essa ordenação é crucial para a posterior construção de variáveis baseadas em desempenho histórico das equipes, que exigem o correto sequenciamento dos jogos.

Para adequar os dados à lógica da modelagem preditiva centrada em uma equipe por vez, foi necessário transformar a estrutura dos dados. Isso foi feito através de um processo de duplicação da base original, no qual as posições das equipes foram invertidas. Ou seja, para cada partida, foi criada uma entrada espelhada, na qual o time que originalmente era o mandante passou a ser tratado como visitante, e vice-versa. Esse espelhamento permitiu que cada linha da base final refletisse a perspectiva de uma única equipe (Team_A) enfrentando um adversário (Team_B), independentemente do mando de campo.

Nesse processo, os nomes das colunas também foram adaptados: os gols marcados pelo time de interesse (Team_A) passaram a ser registrados em Score_A, enquanto os gols do oponente foram registrados em Score_B. Esse procedimento foi aplicado de maneira idêntica nas três bases de dados, correspondentes aos três modelos de regressão logística binária (vitória, empate e derrota), detalhados posteriormente.

Além disso, foi criada a variável categórica Home, com valores "Home" ou "Away", que identifica se o time de interesse jogou a partida como mandante ou visitante. Essa variável será posteriormente utilizada como covariável explicativa, já que o fator casa pode influenciar significativamente o resultado de uma partida de futebol, devido a

aspectos como familiaridade com o campo, apoio da torcida e redução do desgaste físico relacionado a viagens.

3.2 Criação da variável resposta multicategórica

Para cada linha das bases espelhadas, foi calculada a diferença de gols entre o time de interesse e o adversário (dg = Score_A - Score_B). Essa variável foi utilizada como insumo para a criação de uma variável categórica de resultado (Y), que assume três possíveis desfechos:

- "W" (Win), quando dg > 0, indicando vitória do time de interesse;
- "D" (Draw), quando dg == 0, indicando empate;
- "L" (Loss), quando dg < 0, indicando derrota.

A variável Y foi então transformada em fator ordenado com os níveis "L" < "D" < "W", de forma a preservar a ordenação lógica dos desfechos, respeitando a hierarquia natural do desempenho esportivo. Essa estruturação facilita análises descritivas iniciais e também permite flexibilidade para futuras aplicações de métodos ordinalmente sensíveis, ainda que o modelo principal adotado neste estudo seja binário.

3.3 Reestruturação binária para aplicação da estratégia One-vs-Rest

Com o objetivo de aplicar regressão logística binária à predição de resultados multiclasses (vitória, empate e derrota), foi adotada a estratégia de decomposição One-vs-Rest (OvR). Esta abordagem consiste na construção de um modelo separado para cada categoria de interesse, tratando-a como classe positiva, e agrupando as demais categorias como classe negativa. A vantagem desse método está na simplicidade de implementação e interpretação, além de permitir comparações diretas entre as probabilidades estimadas por cada modelo.

Dessa forma, três modelos foram preparados a partir de três versões distintas da base original:

- Modelo de vitória (Y_bin_w): Neste modelo, a classe positiva (1) representa partidas vencidas pela equipe de interesse, enquanto derrotas e empates são considerados classe negativa (0). Essa classificação visa capturar os fatores que aumentam a probabilidade de vitória.

- Modelo de empate (Y_bin_d): Aqui, o valor 1 indica que a partida terminou empatada, ao passo que vitórias e derrotas compõem a classe negativa. O objetivo é identificar padrões que favorecem a ocorrência de igualdade no placar.
- Modelo de derrota (Y_bin_l): Neste caso, o foco está nas derrotas, que formam a classe positiva. Assim, vitórias e empates são agrupados na classe negativa. O modelo busca evidenciar características associadas a desempenhos desfavoráveis.

Para cada um desses modelos, foi criada uma variável binária (Y_bin_w, Y_bin_d, Y_bin_l) com os respectivos critérios de classificação. Essas variáveis foram posteriormente transformadas em fatores com níveis "0" e "1", em conformidade com os requisitos da função glm() para modelagem via regressão logística no R.

A consistência dos critérios de recategorização foi verificada por meio da tabulação de frequências e proporções para cada nova variável resposta binária, garantindo a integridade dos dados e o equilíbrio das classes a serem modeladas.

3.4 Consolidação das bases completas

As três versões espelhadas e recategorizadas da base original foram armazenadas separadamente como df_complete_w, df_complete_d e df_complete_l, correspondendo respectivamente às bases completas para os modelos de vitória, empate e derrota. Cada uma dessas bases contém, além da variável resposta binária, as informações de mando de campo e os placares reorganizados do ponto de vista da equipe de interesse.

Essas bases finais formam o alicerce para a modelagem estatística a ser desenvolvida no capítulo seguinte, sendo utilizadas individualmente em três regressões logísticas distintas, cujos resultados permitirão a inferência sobre os fatores que contribuem para cada tipo de desfecho em uma partida da Premier League.

4. Modelagem Estatística e Avaliação dos Modelos

4.1 Abordagem Metodológica

A partir de uma base de dados simétrica — estruturada para representar a perspectiva de cada time isoladamente em cada partida — foram desenvolvidos três modelos logísticos binários independentes, baseados na estratégia One-vs-Rest (OvR). A variável resposta foi reestruturada para refletir três perspectivas distintas:

Y_bin_w: 1 para vitórias, 0 para derrotas e empates.

Y_bin_d: 1 para empates, 0 para vitórias e derrotas.

Y_bin_l: 1 para derrotas, 0 para vitórias e empates.

As variáveis explicativas incluíram os times envolvidos (Team_A, Team_B) e o fator de mando de campo (Home), com ajuste pelo modelo:

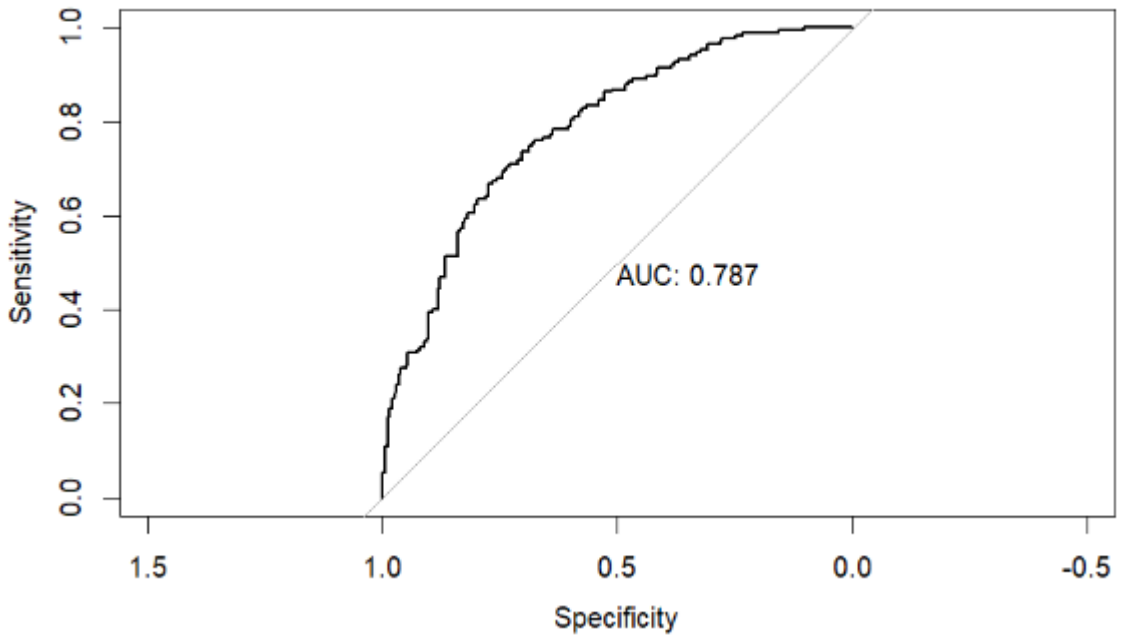
glm(Y_bin ~ 1 + factor(Team_A) + factor(Team_B) + factor(Home), family = binomial)

Essa formulação possibilita a interpretação direta dos coeficientes, além de facilitar a aplicação e replicação dos modelos em diferentes contextos esportivos.

4.2 Análise do Modelo de Vitória (Y_bin_w)

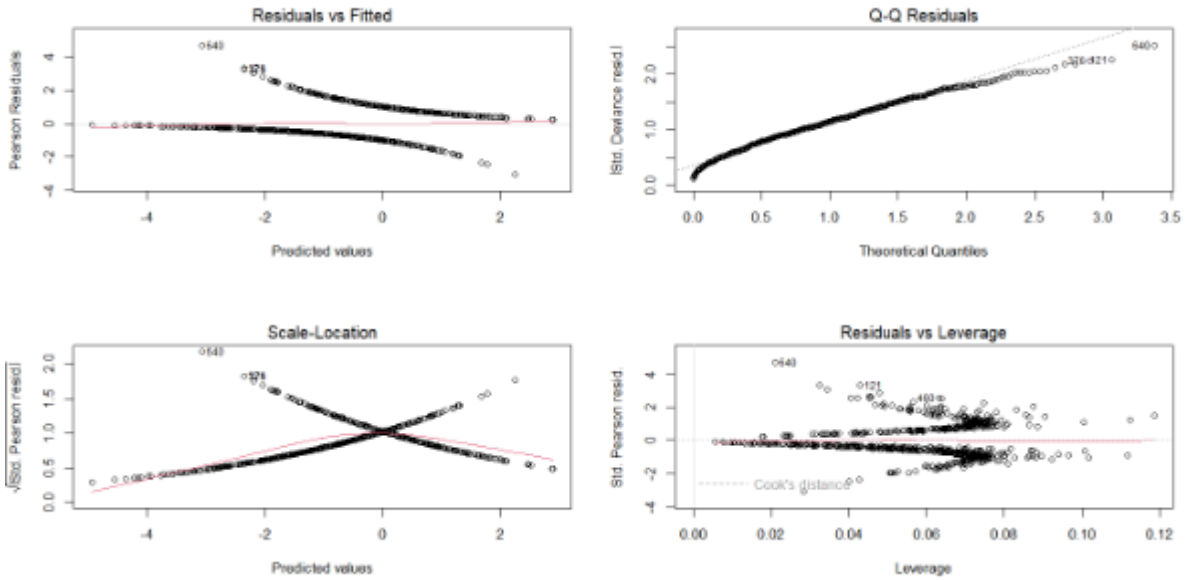
Curva ROC

A curva ROC (Receiver Operating Characteristic) é uma ferramenta fundamental na avaliação de classificadores binários. Ela expressa a relação entre a taxa de verdadeiros positivos (sensibilidade) e a taxa de falsos positivos (1 - especificidade) ao longo de diferentes limiares de corte. Quanto mais próxima a curva estiver do canto superior esquerdo, melhor o desempenho discriminativo do modelo.



No gráfico acima, observa-se uma curva ascendente expressiva, com AUC (Área sob a Curva) de 0.787, o que denota excelente capacidade de distinção entre vitórias e não-vitórias.

Análise de Resíduos



Resíduos vs Valores Ajustados

Estrutura parecida com a do modelo de vitória, com maior concentração de resíduos perto de zero e padrão de curva.

Q-Q Plot

Aponta leve desvio de normalidade nos extremos, o que é aceitável considerando o tamanho da base.

Scale-Location

Aponta certa variação dos resíduos, mas dentro de limites esperados. Não há tendência clara de heterocedasticidade.

Resíduos vs Leverage

Algumas observações com leve influência, mas sem ultrapassar limiares críticos.

Os resíduos apresentam comportamento relativamente estável, com ausência de padrões sistemáticos. Há leve curvatura nas extremidades, mas sem evidência de heterocedasticidade severa ou pontos altamente influentes.

Métricas de Desempenho

```
> tab_w
Confusion Matrix and Statistics

          Reference
Prediction   1   0
         1 119  51
         0  56 154

               Accuracy : 0.7184
                 95% CI : (0.6703, 0.7631)
    No Information Rate : 0.5395
    P-Value [Acc > NIR] : 6.559e-13

                  Kappa : 0.4321

 Mcnemar's Test P-Value : 0.699

            Sensitivity : 0.6800
            Specificity : 0.7512
         Pos Pred Value : 0.7000
         Neg Pred Value : 0.7333
             Prevalence : 0.4605
         Detection Rate : 0.3132
   Detection Prevalence : 0.4474
      Balanced Accuracy : 0.7156

       'Positive' Class : 1
```

Acurácia: 71,8%

Sensibilidade: 68%

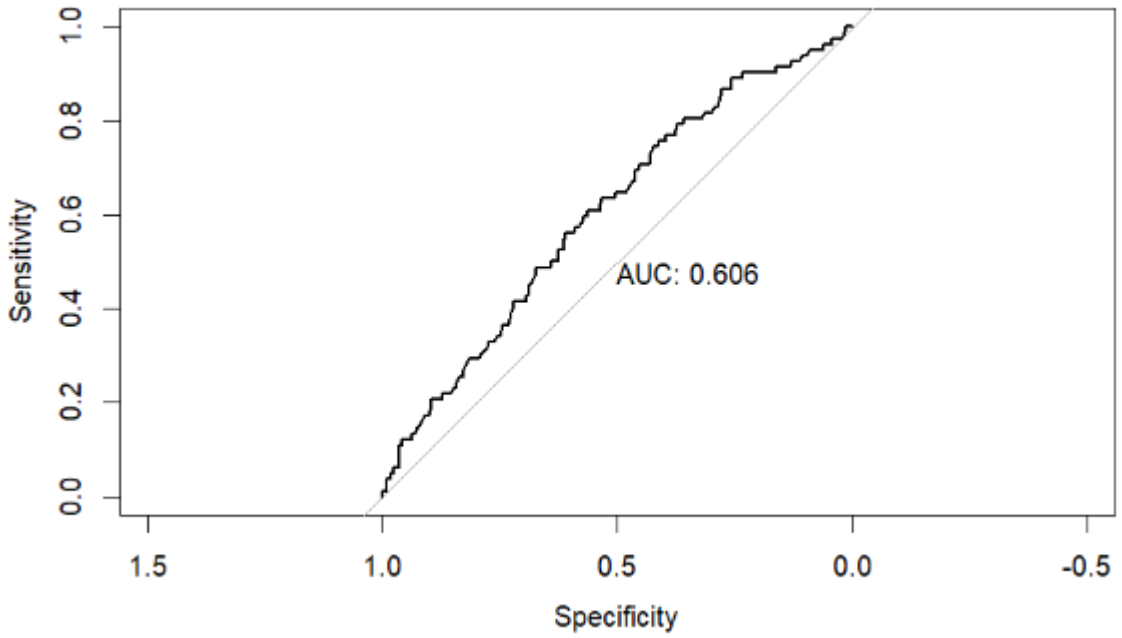
Especificidade: 75,1%

Kappa: 0.43

Esses indicadores demonstram desempenho sólido e equilíbrio entre classes. Além disso, o fator Home teve coeficiente positivo e altamente significativo, validando a hipótese de que jogar em casa aumenta a chance de vitória.

4.3 Análise do Modelo de Empate (Y_bin_d)

Curva ROC



A curva ROC do modelo de empate revela uma área sob a curva (AUC) de 0.606, indicando capacidade discriminativa moderada, mas superior ao nível de aleatoriedade. Embora a curva não se distancie tanto da diagonal de referência (linha de 45°), há evidência de que o modelo consegue, ainda que com dificuldade, diferenciar empates de não-empates.

Por que o modelo de empate é mais difícil de prever?

A previsão de empates apresenta desafios estatísticos bem estabelecidos na literatura. Em primeiro lugar, trata-se da classe menos frequente na base de dados (≈ 21,6%), o que naturalmente dificulta o aprendizado do padrão. Além disso, empates são eventos

que muitas vezes surgem não por superioridade ou inferioridade técnica, mas por equilíbrio ocasional entre os adversários, o que reduz a capacidade preditiva de variáveis estruturais como o fator casa ou os nomes das equipes.

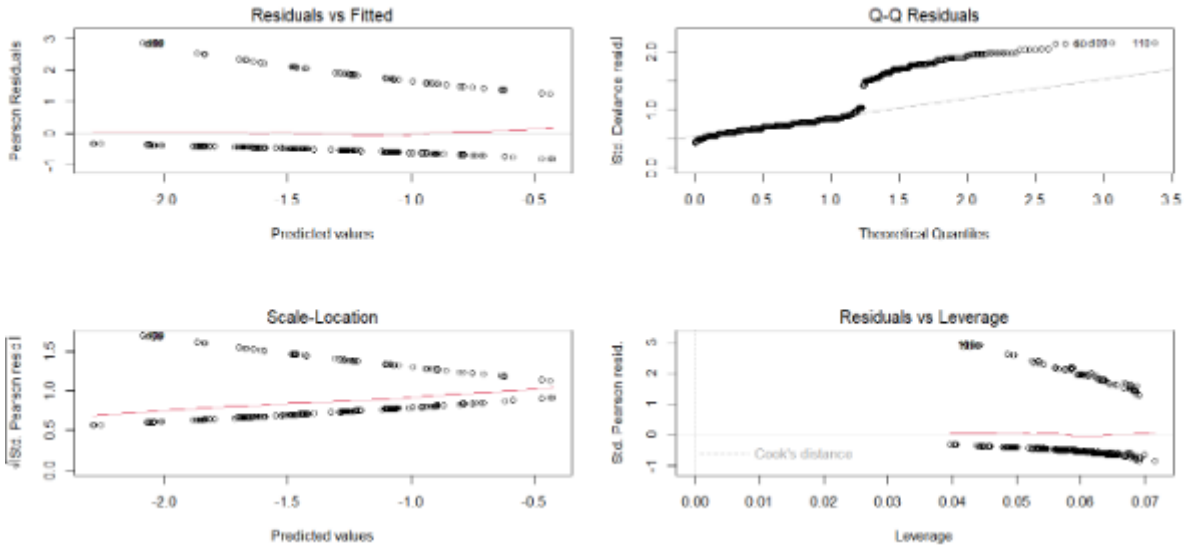
Outro ponto crítico diz respeito à própria estrutura binária do modelo. No modelo de empate (Y_bin_d), a classe 1 representa o empate, enquanto vitórias e derrotas são agrupadas como classe 0. Essa abordagem faz com que o modelo precise identificar um padrão único que diferencie o empate de dois desfechos que, em termos práticos, podem ser bastante distintos entre si, o que aumenta ainda mais a complexidade da tarefa.

Relevância estatística dentro do contexto multiclasse

Ainda que a acurácia do modelo de empate, em termos binários, pareça modesta (≈ 57,4%), é fundamental considerar que a aleatoriedade de um modelo binário gira em torno de 50%. Quando o mesmo modelo é incorporado a um classificador multiclasses (três categorias: vitória, empate e derrota), a aleatoriedade passa a girar em torno de 33,3%, pois agora há três possíveis escolhas.

Nesse sentido, o desempenho do modelo de empate (com acurácia próxima de 57% e AUC acima de 0,6), mostra que, apesar de todas as limitações e da baixa frequência da classe, o modelo ainda foi capaz de identificar padrões com desempenho significativamente superior ao acaso. Isso evidencia a robustez da abordagem, mesmo frente a uma das tarefas estatísticas mais delicadas no futebol.

Análise de Resíduos



Resíduos vs Valores Ajustados

Resíduos pouco variados e quase todos em torno de zero. Isso pode ser consequência do baixo número de empates no dataset, dificultando o ajuste do modelo.

Q-Q Plot

Os resíduos se afastam da normalidade, o que reforça a baixa capacidade do modelo de capturar corretamente os empates, um resultado naturalmente mais difícil de prever.

Scale-Location

Pouca variação, mas possivelmente distorcida pela escassez de eventos “positivos” (empates).

Resíduos vs Leverage

Poucos pontos com alavancagem mais alta, mas sem preocupações maiores de influência.

A análise gráfica dos resíduos revela a presença de algumas observações influentes e leve assimetria nas extremidades. Ainda assim, o padrão geral é aceitável e não compromete a validade do modelo, embora confirme a necessidade de cautela na interpretação de casos isolados.

Métricas de Desempenho

```
> tab_d
Confusion Matrix and Statistics

          Reference
Prediction   1   0
         1  50 130
         0  32 168

               Accuracy : 0.5737
                 95% CI : (0.5222, 0.624)
    No Information Rate : 0.7842
    P-Value [Acc > NIR] : 1

                  Kappa : 0.1211

 Mcnemar's Test P-Value : 2.516e-14

            Sensitivity : 0.6098
            Specificity : 0.5638
         Pos Pred Value : 0.2778
         Neg Pred Value : 0.8400
             Prevalence : 0.2158
         Detection Rate : 0.1316
   Detection Prevalence : 0.4737
      Balanced Accuracy : 0.5868

       'Positive' Class : 1
```

Acurácia: 57,4%

Sensibilidade: 60,9%

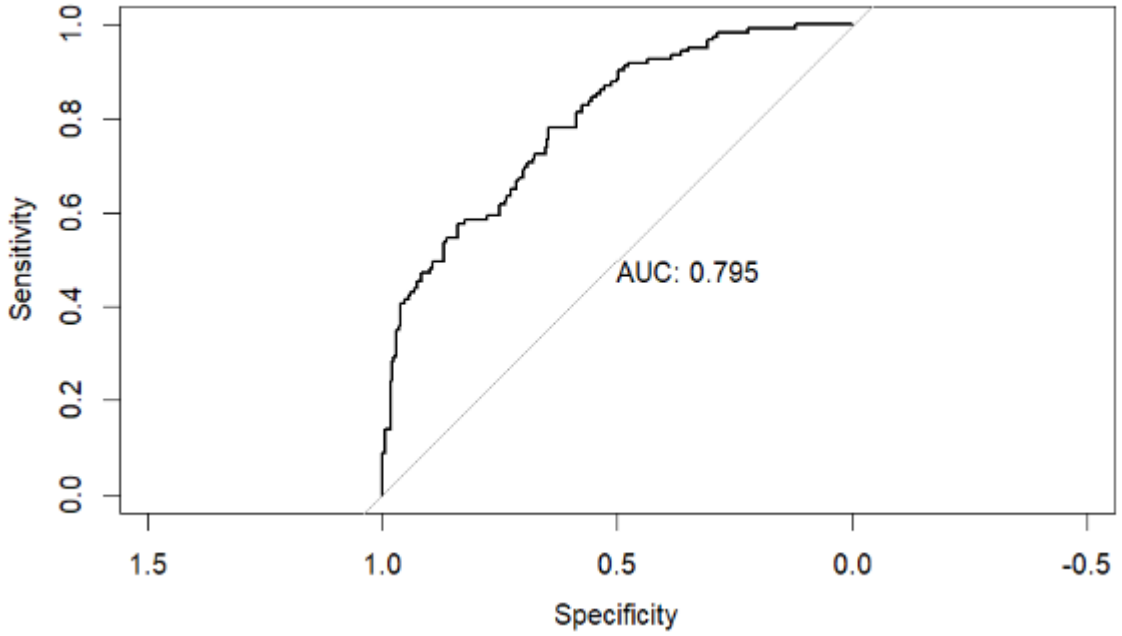
Especificidade: 56,4%

Kappa: 0.12

Apesar de o valor de Kappa ser relativamente baixo, o modelo demonstrou nível de acerto superior ao aleatório, inclusive no cenário multiclasses. Essa performance é estatisticamente válida e reforça que, mesmo em tarefas com ruído elevado, técnicas clássicas de regressão logística ainda entregam resultados relevantes e interpretáveis.

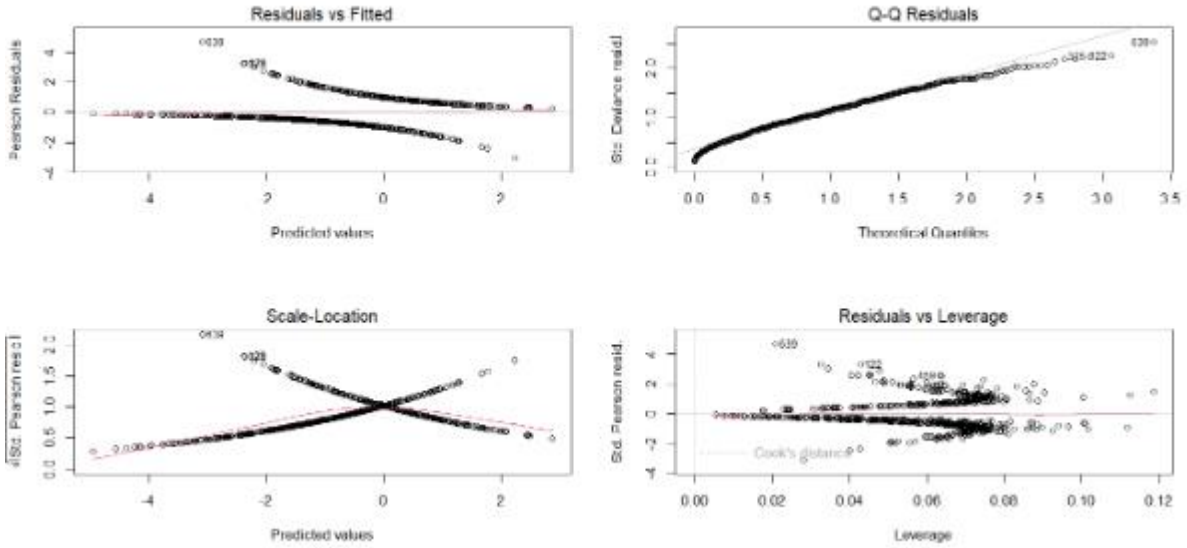
4.4 Análise do Modelo de Derrota (Y_bin_l)

Curva ROC



A AUC de 0.795 confirma a robustez do modelo, cuja curva aproxima-se bastante do ideal. Isso indica alto poder discriminativo ao prever derrotas.

Análise de Resíduos



Resíduos vs Valores Ajustados

Estrutura parecida com a do modelo de vitória, com maior concentração de resíduos perto de zero e padrão de curva.

Q-Q Plot

Aponta leve desvio de normalidade nos extremos, o que é aceitável considerando o tamanho da base.

Scale-Location

Aponta certa variação dos resíduos, mas dentro de limites esperados. Não há tendência clara de heterocedasticidade.

Resíduos vs Leverage

Algumas observações com leve influência, mas sem ultrapassar limiares críticos.

Os resíduos apresentam distribuição adequada, com padrão aleatório e simétrico. Pequenos desvios pontuais não comprometem a validade do modelo.

Métricas de Desempenho

```
> tab_1
Confusion Matrix and Statistics

          Reference
Prediction   1   0
         1  96  91
         0  27 166

               Accuracy : 0.6895
                 95% CI : (0.6403, 0.7357)
    No Information Rate : 0.6763
    P-Value [Acc > NIR] : 0.3126

                  Kappa : 0.3755

 Mcnemar's Test P-Value : 6.647e-09

            Sensitivity : 0.7805
            Specificity : 0.6459
         Pos Pred Value : 0.5134
         Neg Pred Value : 0.8601
             Prevalence : 0.3237
         Detection Rate : 0.2526
   Detection Prevalence : 0.4921
      Balanced Accuracy : 0.7132

       'Positive' Class : 1
```

Acurácia: 68,9%

Sensibilidade: 78%

Especificidade: 64,6%

Kappa: 0.37

A sensibilidade elevada indica que o modelo é particularmente eficaz em identificar jogos com alta chance de derrota.

4.5 Classificador Final Multiclasse com Estratégia One-vs-Rest (OvR)

Após o ajuste dos três modelos logísticos binários (cada um voltado para um desfecho específico (vitória, empate e derrota)), foi aplicada a estratégia One-vs-Rest (OvR) para converter os resultados em uma classificação multiclasses completa. O princípio do OvR consiste em, para cada observação, comparar as probabilidades previstas pelos três modelos e atribuir como rótulo final a classe com maior probabilidade estimada.

Esse método tem duas vantagens principais:

Simplicidade computacional, pois permite aproveitar classificadores binários já bem compreendidos;

Interpretabilidade dos coeficientes, uma vez que cada submodelo mantém a transparência estatística da regressão logística tradicional.

Embora o OvR dependa de modelos binários, sua combinação final resulta em uma abordagem multiclasse, capaz de produzir previsões exclusivas entre vitória, empate ou derrota. A matriz de confusão obtida pela classificação final é apresentada abaixo.

Matriz de Confusão Final — Classificador OvR:

Real \ Previsto	**Derrota (L)**	**Empate (D)**	**Vitória (W)**
Derrota (L)	79	20	24
Empate (D)	30	28	24
Vitória (W)	34	31	110

A matriz acima resume o desempenho do classificador multiclasses:

Acurácia geral: 57,11%

Distribuição real das classes:

Vitórias: 46,05%

Derrotas: 32,37%

Empates: 21,58%

A primeira observação relevante é que o desempenho mais consistente foi na previsão de vitórias, com 110 acertos em 175 jogos (≈ 62,9%). Esse resultado está em consonância com os modelos binários: o modelo de vitória apresentou AUC elevada e coeficientes significativos, o que se refletiu diretamente na classificação final.

O desempenho em derrotas também foi razoável, com 79 acertos (≈ 53,7%), enquanto os empates mostraram novamente o maior desafio: apenas 28 acertos em 82 jogos (≈ 34,1%). Ainda assim, esse resultado supera o nível de aleatoriedade esperada em um cenário com três classes (≈ 33,3%), o que valida a eficácia da abordagem mesmo para a classe mais difícil.

Considerações estatísticas

A estratégia OvR não busca modelar diretamente a interação entre as três classes, mas sim decompor o problema em comparações binárias mais simples. Com isso, as probabilidades geradas não são mutuamente excludentes nem necessariamente somam 1, o que justifica o uso da maior probabilidade como critério de decisão. Ainda assim, o desempenho global do classificador demonstra que:

A combinação dos três modelos consegue capturar padrões relevantes e não triviais dos resultados;

A acurácia final de 57,11% é substancialmente superior ao classificador ingênuo, que escolheria sempre a classe mais frequente (vitória), atingindo apenas 46,05% de acerto;

A capacidade de acertar todos os três tipos de resultado, mesmo que em diferentes magnitudes, mostra que o modelo se aproxima de um sistema de apoio à decisão esportiva viável e interpretável.

Além disso, como o modelo é inteiramente baseado em variáveis públicas e disponíveis (nome dos times e mando de campo), ele demonstra um excelente custo-benefício analítico, sendo replicável por profissionais de estatística, esporte ou negócios.

5. Conclusão

O presente trabalho teve como objetivo central desenvolver um modelo preditivo para resultados de partidas da Premier League 2023/2024 utilizando regressão logística binária com a estratégia One-vs-Rest (OvR). A abordagem metodológica adotada permitiu converter um problema originalmente multiclasse (prever vitória, empate ou derrota) em três modelos binários independentes, cada um focado em uma classe específica.

A escolha pela regressão logística se justifica por sua capacidade interpretativa, robustez teórica e simplicidade de aplicação. Mesmo frente a alternativas mais complexas, como redes neurais ou modelos de aprendizado de máquina, a regressão logística oferece transparência estatística, o que facilita tanto a leitura de coeficientes quanto a replicabilidade do estudo em contextos profissionais.

A base de dados foi construída de forma simétrica, com duplicação dos registros para contemplar a perspectiva de ambos os times em cada partida. As variáveis explicativas utilizadas (Team_A, Team_B e o fator Home) foram selecionadas com base em sua disponibilidade pública e no potencial explicativo direto sobre o resultado das partidas.

Principais Resultados

Os três modelos binários apresentaram desempenhos distintos, refletindo a natureza estatística de cada desfecho:

Modelo de vitória (Y_bin_w): Obteve AUC de 0.787 e acurácia de 71,8%, com impacto significativo do mando de campo e de equipes consideradas frágeis como visitantes. O modelo demonstrou ótimo poder de discriminação e consistência estatística.

Modelo de derrota (Y_bin_l): Apresentou AUC de 0.795 e acurácia de 68,9%, reforçando a importância do mando de campo e da força relativa dos adversários. A sensibilidade elevada (78%) indica grande capacidade de identificação de derrotas iminentes.

Modelo de empate (Y_bin_d): Foi o mais desafiador, com AUC de 0.606 e acurácia de 57,4%. A dificuldade em prever empates é esperada por se tratar de uma classe estatisticamente menos frequente e com padrões mais difusos. Apesar disso, o desempenho ainda superou o nível de aleatoriedade binária (50%) e, no contexto multiclasses, superou os 33,3%, revelando que o modelo, mesmo limitado, conseguiu identificar algum padrão preditivo para empates.

A combinação dos três modelos por meio da estratégia OvR resultou em um classificador final multiclasse com acurácia de 57,11%, superior ao classificador ingênuo que sempre prevê a classe mais frequente (vitória), com acurácia de apenas 46,05%. Essa diferença evidencia que o modelo não apenas aprendeu padrões relevantes, mas também os aplicou de forma coerente na classificação final.

Contribuições e Implicações

Este estudo contribui para o campo de modelagem preditiva esportiva ao mostrar que modelos estatísticos simples e interpretáveis são capazes de oferecer previsões eficazes, mesmo diante da complexidade inerente ao futebol. A aplicação da estratégia OvR com regressão logística permitiu:

Avaliar separadamente os padrões que levam à vitória, empate ou derrota;

Medir o impacto estatístico do mando de campo e da composição dos adversários;

Criar um sistema preditivo com aplicação prática em análise esportiva, casas de apostas, cobertura jornalística e até planejamento técnico.

Além disso, a análise de resíduos e curvas ROC mostrou que os modelos foram bem ajustados, sem grandes indícios de violação dos pressupostos estatísticos, especialmente nos modelos de vitória e derrota.

Limitações

Como todo modelo estatístico, este trabalho também apresenta limitações. A principal delas é a restrição do conjunto de variáveis utilizadas. Fatores contextuais relevantes como lesões, escalações, momento da temporada, estatísticas de desempenho (como finalizações ou posse de bola), entre outros, não foram incorporados. Além disso, a base utilizada considera apenas a temporada atual, o que limita o aprendizado a eventos recentes e reduz a capacidade de generalização histórica.

Outro ponto a ser considerado é o desequilíbrio de classes, especialmente na categoria "empate", que representa pouco mais de 21% dos dados. Esse desbalanceamento dificulta a modelagem e reduz a sensibilidade do modelo nessa classe.

Possibilidades Futuras

Com base nos resultados obtidos e nas limitações identificadas, este trabalho abre portas para diversas possibilidades de aprofundamento, como:

- Ampliação do conjunto de variáveis, incluindo estatísticas táticas e dados históricos;
- Calibragem das probabilidades preditas, visando maior precisão na tomada de decisão;
- Avaliação de abordagens alternativas, como regressão logística multinomial, árvores de decisão, Random Forest ou modelos baseados em aprendizado profundo (SEN et al., 2019);
- Aplicação de técnicas de balanceamento de classes explícitas, como oversampling ou penalização (ASSUNÇÃO; PRATES, 2024);
- Análise temporal, incorporando a sequência de jogos para capturar tendências ou variações de desempenho ao longo da temporada (MACHADO; LOPES, 2017).

Considerações Finais

Conclui-se que a regressão logística binária com estratégia One-vs-Rest se mostrou uma ferramenta estatística eficaz, robusta e aplicável à realidade do futebol profissional, mesmo em uma das ligas mais equilibradas do mundo, como a Premier League. A acurácia obtida, aliada à clareza interpretativa dos coeficientes, valida o modelo tanto em termos preditivos quanto como instrumento de análise tática e estratégica.

Mais do que buscar a perfeição estatística, este trabalho reforça a importância da compreensão crítica dos dados e dos limites do futebol como fenômeno imprevisível, onde estatísticas ajudam a interpretar, mas não substituem o acaso e o fator humano inerentes ao esporte.

REFERÊNCIAS BIBLIOGRÁFICAS

ASSUNÇÃO, Gabriel O.; IZBICKI, Rafael; PRATES, Marcos O. Is augmentation effective in improving prediction in imbalanced datasets? *Journal of Data Science*, 2024. p. 1–16.

AZNAR-GIMENO, Rocío et al. Comparing the Min–Max–Median/IQR Approach with the Min–Max Approach, Logistic Regression and XGBoost, Maximising the Youden Index. *Symmetry*, v. 15, n. 3, p. 756, 2023.

CORDEIRO, Gauss M.; DEMÉTRIO, Clarice G. B.; MORAL, Rafael D. A. *Modelos lineares generalizados e aplicações*. São Paulo: Blucher, 2024.

MACHADO, J. T.; LOPES, A. M. On the mathematical modeling of soccer dynamics. *Communications in Nonlinear Science and Numerical Simulation*, v. 53, p. 142–153, 2017.

PADILHA, Carlos R. Incorporating contextual variables in football match outcome prediction. In: *Congresso Brasileiro de Estatística Aplicada*. São Paulo: [s.n.], 2022.

PAULA, Gilberto A. *Modelos de regressão: com apoio computacional*. São Paulo: IME-USP, 2024.

RIMAL, Yagya Nath; SHARMA, Navneet; RATHORE, Vijay Singh. Ensemble machine learning one-versus-rest multilevel grade classification and prediction. In: *International Conference on Universal Threats in Expert Applications and Solutions*. Singapore: Springer Nature Singapore, 2024. p. 487–507.

SEN, P. C.; HAJRA, M.; GHOSH, M. Supervised classification algorithms in machine learning: A survey and review. In: *Emerging Technology in Modelling and Graphics: Proceedings of IEM Graph 2018*. Singapore: Springer Singapore, 2019. p. 99–111.

SILVA, José Carlos. Análise do futebol no Brasil como um fenômeno sociocultural. *Revista Digital - Buenos Aires*, v. 13, n. 159, 2011. Disponível em: https://www.efdeportes.com/efd159/futebol-como-um-fenomeno-sociocultural.htm.

ZHOU, Z. H.; LIU, X. Y. On multi-class cost-sensitive learning. *Computational Intelligence*, v. 26, n. 3, p. 232–257, 2010.